

Uniwersytet Ekonomiczny w Katowicach
Kierunek: Informatyka i ekonometria

Paulina Ryguła i Filip Bednorz

Predykcja intencji zakupowej użytkownika sklepu internetowego

Uczenie maszynowe w SAS

KATOWICE 2026

Spis treści

Wstęp	3
Cel projektu, problem badawczy i metodyka	3
2.1. Cel projektu	3
2.2. Problem badawczy	4
2.3. Pytania badawcze	4
2.4. Zastosowana metodyka	4
Opis zbioru danych	5
3.1. Źródło danych	5
3.2. Charakterystyka zmiennych	6
3.3. Kontrola jakości danych	6
Eksploracyjna analiza danych	16
Analiza zmiennej docelowej	17
Analiza korelacji i wybór zmiennych	19
Wizualizacja wybranych zmiennych	24
Przygotowanie danych do modelowania	38
Budowa modeli klasyfikacyjnych	41
Porównanie modeli	47
Walidacja krzyżowa	49
Ocena stabilności najlepszego modelu metodą bootstrap	51
Strojenie hiperparametrów	53
Krzywa ROC i AUC	57
Analiza ważności cech	59
Wnioski końcowe	61
Spis rysunków	66
Spis tabel	67
Źródło danych	67

Wstęp

Rozwój handlu internetowego powoduje, że sklepy online gromadzą coraz większą ilość danych o zachowaniu użytkowników. Dane te mogą obejmować między innymi liczbę odwiedzonych stron, czas spędzony w różnych częściach serwisu, współczynniki odrzuceń, typ użytkownika, źródło ruchu oraz informację o tym, czy sesja zakończyła się zakupem. Z punktu widzenia przedsiębiorstwa szczególnie istotne jest przewidywanie intencji zakupowej użytkownika, ponieważ taka informacja może wspierać personalizację oferty, działania marketingowe, rekomendacje produktów oraz decyzje dotyczące optymalizacji strony internetowej.

Niniejszy projekt dotyczy predykcji intencji zakupowej użytkownika sklepu internetowego. Analizowany problem ma charakter klasyfikacji binarnej, ponieważ zmienna docelowa Revenue przyjmuje dwie wartości: True, gdy dana sesja zakończyła się zakupem, oraz False, gdy zakup nie nastąpił. Projekt został wykonany na rzeczywistym zbiorze danych Online Shoppers Purchasing Intention Dataset pochodzącym z UCI Machine Learning Repository. Zbiór ten był również podstawą badań nad predykcją zachowania użytkowników sklepów internetowych w czasie rzeczywistym.

W projekcie przeprowadzono pełny proces badawczy: określono cel i pytania badawcze, opisano dane, wykonano eksploracyjną analizę danych, przygotowano dane do modelowania, zbudowano kilka modeli klasyfikacyjnych, porównano ich jakość, przeprowadzono walidację krzyżową, wykonano strojenie hiperparametrów, oceniono krzywą ROC i AUC oraz zinterpretowano ważność cech w najlepszym modelu. Raport przedstawia wyniki w sposób umożliwiający ocenę zarówno strony technicznej, jak i biznesowej zastosowanego rozwiązania.

Cel projektu, problem badawczy i metodyka

2.1. Cel projektu

Głównym celem projektu było zbudowanie modelu uczenia maszynowego, który na podstawie informacji o sesji użytkownika sklepu internetowego przewiduje, czy użytkownik dokona zakupu. Cel ma charakter praktyczny, ponieważ poprawna identyfikacja użytkowników o wysokim prawdopodobieństwie zakupu może wspierać

działania sprzedażowe i marketingowe. Z perspektywy analitycznej celem było również porównanie skuteczności kilku metod klasyfikacyjnych oraz wybór modelu, który najlepiej radzi sobie z przewidywaniem klasy pozytywnej, czyli sesji zakończonych zakupem.

2.2. Problem badawczy

Problem badawczy można sformułować następująco: czy na podstawie danych opisujących aktywność użytkownika w sklepie internetowym można skutecznie przewidzieć, czy dana sesja zakończy się zakupem? Jest to problem klasyfikacji nadzorowanej, ponieważ dla każdej obserwacji znana jest wartość zmiennej docelowej Revenue. Modele uczą się więc zależności między cechami wejściowymi a informacją o zakupie na podstawie danych historycznych, a następnie są oceniane na niewidzianym wcześniej zbiorze testowym

2.3. Pytania badawcze

Sformułowano następujące pytania badawcze:

- Czy dane opisujące zachowanie użytkownika na stronie internetowej pozwalają przewidywać dokonanie zakupu?
- Który z porównanych modeli klasyfikacyjnych najlepiej równoważy precyzję i czułość dla klasy zakupowej?
- Które cechy użytkownika i sesji mają największe znaczenie dla predykcji zakupu?
- Czy wyniki najlepszego modelu są stabilne w walidacji krzyżowej?

2.4. Zastosowana metodyka

Proces badawczy został podzielony na kilka etapów. W pierwszym etapie wczytano dane z repozytorium UCI, sprawdzono ich strukturę, typy zmiennych, braki danych oraz duplikaty. Następnie przeprowadzono eksploracyjną analizę danych obejmującą rozkład zmiennej docelowej, analizę korelacji oraz wizualizacje wybranych zmiennych numerycznych i kategorycznych. W kolejnym etapie dane zostały przygotowane do modelowania poprzez kodowanie zmiennych kategorycznych, zamianę zmiennej docelowej na postać 0/1, podział na zbiór treningowy i testowy oraz standaryzację cech.

Do modelowania wykorzystano cztery metody klasyfikacyjne: regresję logistyczną, drzewo decyzyjne, las losowy oraz metodę k najbliższych sąsiadów. Tak dobrany zestaw metod pozwala porównać model liniowy, pojedynczy model drzewiasty, metodę zespołową oraz metodę opartą na podobieństwie obserwacji. Implementację wykonano w środowisku Python z wykorzystaniem biblioteki scikit-learn, która udostępnia spójny interfejs do budowy, walidacji i oceny modeli uczenia maszynowego.

Jako miary jakości zastosowano accuracy, precision, recall oraz F1-score. Ze względu na niezbalansowanie klas szczególną uwagę zwrócono na F1-score, ponieważ sama dokładność mogłaby prowadzić do zbyt optymistycznej oceny modelu. Dodatkowo zastosowano 5-krotną walidację krzyżową, metodę bootstrap dla wyniku accuracy, strojenie hiperparametrów Random Forest za pomocą GridSearchCV, krzywą ROC, wartość AUC oraz analizę ważności cech.

Opis zbioru danych

3.1. Źródło danych

W projekcie wykorzystano zbiór Online Shoppers Purchasing Intention Dataset dostępny w UCI Machine Learning Repository. Zbiór zawiera dane dotyczące sesji użytkowników sklepu internetowego i służy do przewidywania, czy dana sesja zakończyła się zakupem. Według opisu repozytorium zbiór obejmuje 12 330 sesji oraz zmienne opisujące zachowanie użytkownika, informacje techniczne i kontekst wizyty. Dane są rzeczywiste, a nie syntetycznie wygenerowane, co zwiększa wartość projektu z punktu widzenia zastosowań praktycznych.

Tabela 1. Podstawowa charakterystyka zbioru danych.

Element	Wartość
Nazwa zbioru	Online Shoppers Purchasing Intention Dataset
Źródło	UCI Machine Learning Repository
Liczba obserwacji przed czyszczeniem	12 330
Liczba kolumn przed kodowaniem	18
Zmienna docelowa	Revenue
Typ problemu	Klasyfikacja binarna

Liczba braków danych	0
Liczba wykrytych duplikatów	125
Liczba obserwacji po usunięciu duplikatów	12 205

3.2. Charakterystyka zmiennych

Zbiór danych zawiera zmienne opisujące aktywność użytkownika w różnych częściach sklepu internetowego. Zmienne Administrative, Informational oraz ProductRelated informują o liczbie odwiedzonych stron określonego typu, natomiast odpowiadające im zmienne z końcówką Duration opisują czas spędzony w tych obszarach. Zmienne BounceRates i ExitRates odnoszą się do sposobu opuszczania strony, a PageValues opisuje wartość stron odwiedzonych przez użytkownika. Pozostałe cechy obejmują między innymi miesiąc wizyty, typ użytkownika, informację o wizycie weekendowej, system operacyjny, przeglądarkę, region oraz typ ruchu.

Tabela 2. Grupy zmiennych wykorzystanych w projekcie.

Grupa	Zmienne
Zmienne behawioralne	Administrative, Administrative_Duration, Informational, Informational_Duration, ProductRelated, ProductRelated_Duration
Zmienne opisujące opuszczanie strony	BounceRates, ExitRates
Zmienna wartości strony	PageValues
Zmienne kontekstowe	SpecialDay, Month, Weekend
Zmienne techniczne i segmentacyjne	OperatingSystems, Browser, Region, TrafficType, VisitorType
Zmienna docelowa	Revenue

W analizie należy zwrócić uwagę, że część zmiennych ma charakter kategoriowy, mimo że jest zapisana liczbowo, na przykład OperatingSystems, Browser, Region oraz TrafficType. W zastosowanym notebooku zmienne te pozostały w postaci kodów liczbowych. Zmienne typu tekstowego i logicznego, takie jak Month, VisitorType i Weekend, zostały uwzględnione w procesie kodowania przed modelowaniem

3.3. Kontrola jakości danych

Przed modelowaniem sprawdzono kompletność danych oraz występowanie powielonych obserwacji. W zbiorze nie stwierdzono braków danych, co oznacza, że

nie było potrzeby imputacji wartości brakujących. Wykryto natomiast 125 duplikatów, które zostały usunięte. Po tym etapie do dalszej analizy wykorzystano 12 205 obserwacji. Usunięcie duplikatów było uzasadnione, ponieważ powtarzające się rekordy mogłyby sztucznie wzmacniać wybrane wzorce w danych i wpływać na wyniki modeli.

Pierwsze 5 wierszy danych:

	Administrative	Administrative_Duration	Informational	Informational_Duration	ProductRelated	ProductRelated_Duration	BounceRates	ExitRates
0	0	0.0	0	0.0	1	0.000000	0.20	0.20
1	0	0.0	0	0.0	2	64.000000	0.00	0.10
2	0	0.0	0	0.0	1	0.000000	0.20	0.20
3	0	0.0	0	0.0	2	2.666667	0.05	0.14
4	0	0.0	0	0.0	10	627.500000	0.02	0.05

Rysunek 1 Pierwsze pięć wierszy zbioru danych


PageValues	SpecialDay	Month	OperatingSystems	Browser	Region	TrafficType	VisitorType	Weekend	Revenue
0.0	0.0	Feb	1	1	1	1	Returning_Visitor	False	False
0.0	0.0	Feb	2	2	1	2	Returning_Visitor	False	False
0.0	0.0	Feb	4	1	9	3	Returning_Visitor	False	False
0.0	0.0	Feb	3	2	2	4	Returning_Visitor	False	False
0.0	0.0	Feb	3	3	1	4	Returning_Visitor	True	False

Rysunek 2 Pierwsze pięć wierszy zbioru danych cd.

Na Rysunku 1 i Rysunku 2 znajduje się podgląd pierwszych pięciu obserwacji analizowanego zbioru danych. Przedstawienie początkowych rekordów pozwala wstępnie ocenić strukturę danych, nazwy kolumn, typy zmiennych oraz sposób zapisu wartości. W widocznych wierszach znajdują się zarówno zmienne liczbowe, takie jak Administrative, Administrative_Duration, ProductRelated, ProductRelated_Duration, BounceRates, ExitRates, PageValues i SpecialDay, jak również zmienne kategoryczne, między innymi Month, VisitorType, Weekend oraz zmienna docelowa Revenue.

Na podstawie pierwszych obserwacji można zauważyć, że dane opisują pojedyncze sesje użytkowników sklepu internetowego. Każdy wiersz odpowiada jednej wizycie użytkownika, natomiast kolumny opisują zachowanie użytkownika podczas tej wizyty. Przykładowo zmienna ProductRelated informuje o liczbie odwiedzonych stron związanych z produktami, a ProductRelated_Duration określa czas spędzony na tych stronach. Z kolei zmienne BounceRates i ExitRates opisują wskaźniki związane z opuszczaniem strony przez użytkowników.

W pierwszych pięciu obserwacjach zmienna Revenue przyjmuje wartość False, co oznacza, że żadna z tych sesji nie zakończyła się zakupem. Jest to istotna informacja na etapie wstępnej eksploracji danych, ponieważ już na początku sugeruje konieczność dalszego sprawdzenia rozkładu zmiennej docelowej i ewentualnego niezbalansowania klas.

A dark rectangular box with white text. The text reads "Rozmiar zbioru danych:" on the first line and "(12330, 18)" on the second line.

Rysunek 3 Rozmiar zbioru danych

Na Rysunku 3 znajduje się informacja o pierwotnym rozmiarze analizowanego zbioru danych. Zbiór zawiera 12 330 obserwacji oraz 18 kolumn. Oznacza to, że baza danych obejmuje 12 330 zarejestrowanych sesji użytkowników sklepu internetowego, a każda sesja została opisana za pomocą 18 zmiennych. Informacja o rozmiarze zbioru danych jest ważna z punktu widzenia dalszego procesu analitycznego. Liczba obserwacji jest wystarczająco duża, aby możliwe było zastosowanie klasycznych metod uczenia maszynowego, podział danych na zbiór treningowy i testowy oraz przeprowadzenie walidacji krzyżowej. Jednocześnie liczba zmiennych nie jest nadmiernie wysoka, co ułatwia interpretację wyników i pozwala przeprowadzić szczegółową analizę eksploracyjną.

Warto zaznaczyć, że rozmiar ten dotyczy danych przed usunięciem duplikatów. Na późniejszym etapie przygotowania danych liczba obserwacji została zmniejszona, ponieważ wykryto i usunięto powtarzające się rekordy.

	name	role	type	demographic	description	units	missing_values
0	Administrative	Feature	Integer	None	None	None	no
1	Administrative_Duration	Feature	Integer	None	None	None	no
2	Informational	Feature	Integer	None	None	None	no
3	Informational_Duration	Feature	Integer	None	None	None	no
4	ProductRelated	Feature	Integer	None	None	None	no
5	ProductRelated_Duration	Feature	Continuous	None	None	None	no
6	BounceRates	Feature	Continuous	None	None	None	no
7	ExitRates	Feature	Continuous	None	None	None	no
8	PageValues	Feature	Integer	None	None	None	no
9	SpecialDay	Feature	Integer	None	None	None	no
10	Month	Feature	Categorical	None	None	None	no
11	OperatingSystems	Feature	Integer	None	None	None	no
12	Browser	Feature	Integer	None	None	None	no
13	Region	Feature	Integer	None	None	None	no
14	TrafficType	Feature	Integer	None	None	None	no
15	VisitorType	Feature	Categorical	None	None	None	no
16	Weekend	Feature	Binary	None	None	None	no
17	Revenue	Target	Binary	None	None	None	no

Rysunek 4 Informacje o typach danych

Na Rysunku 4 znajduje się zestawienie metadanych zmiennych wykorzystanych w zbiorze danych Online Shoppers Purchasing Intention. Tabela przedstawia wszystkie 18 zmiennych występujących w analizowanym zbiorze danych wraz z ich podstawową charakterystyką. W kolumnie name podano nazwy zmiennych, w kolumnie role określono ich funkcję w analizie, natomiast kolumna type informuje o ogólnym typie danej zmiennej. Z przedstawionej tabeli wynika, że większość zmiennych pełni rolę cech objaśniających, oznaczonych jako Feature. Są to zmienne wykorzystywane przez modele uczenia maszynowego do przewidywania wartości zmiennej docelowej. Do tej grupy należą między innymi Administrative, Administrative_Duration, Informational, ProductRelated, BounceRates, ExitRates, PageValues, Month, VisitorType oraz Weekend. Jediną zmienną oznaczoną jako Target jest Revenue. Oznacza to, że jest ona zmienną docelową, którą modele klasyfikacyjne mają przewidywać. Zmienna ta ma charakter binarny, ponieważ przyjmuje dwie wartości: True, gdy sesja zakończyła się zakupem, oraz False, gdy użytkownik nie dokonał zakupu. Tabela wskazuje również, że w zbiorze występują różne typy zmiennych.

Część z nich ma charakter liczbowy, na przykład Administrative, Informational, ProductRelated, PageValues i SpecialDay. Zmienne ProductRelated_Duration, BounceRates oraz ExitRates zostały opisane jako zmienne ciągłe. W zbiorze obecne są także zmienne katagoryczne, takie jak Month i VisitorType, oraz zmienne binarne, czyli Weekend i Revenue. Istotna jest również kolumna missing_values, która wskazuje, że dla każdej zmiennej oznaczono brak wartości brakujących. Oznacza to, że zbiór danych jest kompletny pod względem pustych wartości, co upraszcza etap przygotowania danych do modelowania. Nie było konieczne stosowanie imputacji braków danych, czyli uzupełniania ich średnią, medianą, dominantą lub inną metodą. Warto zaznaczyć, że tabela ma charakter opisowy i porządkujący. Pokazuje logiczną strukturę zbioru danych oraz pozwala określić, które zmienne są predyktorami, a która zmienna jest etykietą klasy. Jest to ważny element raportu, ponieważ ułatwia zrozumienie, jakie informacje zostały wykorzystane w procesie budowy modeli klasyfikacyjnych.

W projekcie wykorzystano zmienne opisujące pojedyncze sesje użytkowników sklepu internetowego. Zmienne te zostały podzielone na kilka grup, ponieważ różnią się charakterem, sposobem interpretacji oraz znaczeniem dla procesu modelowania. Głównym celem takiego podziału było uporządkowanie danych przed etapem eksploracyjnej analizy danych oraz budowy modeli klasyfikacyjnych. Pierwszą grupę stanowią zmienne ilościowe opisujące aktywność użytkownika w serwisie. Do tej grupy należą między innymi Administrative, Administrative_Duration, Informational, Informational_Duration, ProductRelated oraz ProductRelated_Duration. Zmienne te informują, ile stron danego typu odwiedził użytkownik oraz ile czasu spędził w określonych częściach sklepu internetowego. Szczególnie istotne są zmienne związane ze stronami produktowymi, ponieważ mogą wskazywać na stopień zainteresowania użytkownika ofertą sklepu. Drugą grupę tworzą zmienne opisujące jakość i charakter sesji użytkownika. Należą do niej BounceRates, ExitRates, PageValues oraz SpecialDay. Zmienna BounceRates odnosi się do współczynnika odrzuceń, natomiast ExitRates opisuje częstość opuszczania strony przez użytkowników. Wysokie wartości tych zmiennych mogą sugerować niższe zaangażowanie użytkownika. Zmienna PageValues informuje o wartości odwiedzanych stron z perspektywy potencjalnej konwersji, dlatego może mieć istotne znaczenie przy przewidywaniu zakupu. Z kolei SpecialDay wskazuje bliskość wizyty

względem szczególnego dnia, który może wpływać na zachowania zakupowe. Kolejną grupę stanowią zmienne kategoryczne oraz techniczne. Do zmiennych kategorycznych należą Month, VisitorType oraz Weekend. Zmienna Month określa miesiąc wizyty, VisitorType opisuje typ użytkownika, na przykład użytkownika nowego lub powracającego, natomiast Weekend informuje, czy sesja odbyła się w weekend. Dodatkowo w zbiorze występują zmienne OperatingSystems, Browser, Region oraz TrafficType. Chociaż są one zapisane w postaci liczbowej, należy interpretować je jako zakodowane kategorie, ponieważ poszczególne wartości oznaczają określony system operacyjny, przeglądarkę, region lub typ źródła ruchu. Zmienną docelową w projekcie jest Revenue. Jest to zmienna binarna, która informuje, czy dana sesja zakończyła się zakupem. Wartość True oznacza, że użytkownik dokonał zakupu, natomiast wartość False oznacza brak zakupu. Z tego powodu analizowany problem ma charakter klasyfikacji binarnej, a zadaniem modeli uczenia maszynowego jest przypisanie każdej sesji do jednej z dwóch klas: zakup lub brak zakupu. Podział zmiennych na grupy jest istotny również z punktu widzenia przygotowania danych do modelowania. Zmienne numeryczne mogą być bezpośrednio wykorzystywane przez część algorytmów, natomiast zmienne kategoryczne wymagają wcześniejszego zakodowania. W projekcie zastosowano kodowanie zmiennych jakościowych, tak aby mogły zostać wykorzystane przez modele klasyfikacyjne.

```

Informacje o typach danych:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 12330 entries, 0 to 12329
Data columns (total 18 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Administrative                        12330 non-null  int64
1   Administrative_Duration              12330 non-null  float64
2   Informational                        12330 non-null  int64
3   Informational_Duration               12330 non-null  float64
4   ProductRelated                      12330 non-null  int64
5   ProductRelated_Duration              12330 non-null  float64
6   BounceRates                          12330 non-null  float64
7   ExitRates                           12330 non-null  float64
8   PageValues                          12330 non-null  float64
9   SpecialDay                          12330 non-null  float64
10  Month                               12330 non-null  object
11  OperatingSystems                    12330 non-null  int64
12  Browser                             12330 non-null  int64
13  Region                             12330 non-null  int64
14  TrafficType                         12330 non-null  int64
15  VisitorType                         12330 non-null  object
16  Weekend                             12330 non-null  bool
17  Revenue                             12330 non-null  bool
dtypes: bool(2), float64(7), int64(7), object(2)
memory usage: 1.5+ MB

```

Rysunek 5 Informacje o typach danych

Na Rysunku 5 znajduje się wynik funkcji informującej o strukturze zbioru danych, typach zmiennych oraz liczbie wartości niepustych w poszczególnych kolumnach. Z przedstawionego zestawienia wynika, że zbiór składa się z 18 kolumn oraz 12 330 obserwacji. Dla każdej zmiennej podano liczbę wartości niepustych, co pozwala wstępnie ocenić kompletność danych. Wszystkie kolumny posiadają po 12 330 wartości niepustych, co oznacza, że na tym etapie nie stwierdzono braków danych. Jest to korzystna sytuacja z punktu widzenia modelowania, ponieważ nie ma konieczności stosowania metod imputacji, czyli uzupełniania brakujących wartości. W strukturze danych występują różne typy zmiennych. Część zmiennych ma charakter liczbowy całkowity, na przykład Administrative, Informational, ProductRelated,

OperatingSystems, Browser, Region oraz TrafficType. Inne zmienne są zapisane jako liczby zmiennoprzecinkowe, na przykład Administrative_Duration, ProductRelated_Duration, BounceRates, ExitRates, PageValues i SpecialDay. Zmienne Month oraz VisitorType mają typ tekstowy, natomiast Weekend i Revenue są zmiennymi logicznymi. Należy jednak podkreślić, że sam techniczny typ danych nie zawsze oznacza rzeczywisty charakter zmiennej. Przykładowo zmienne OperatingSystems, Browser, Region oraz TrafficType są zapisane jako liczby całkowite, ale w sensie analitycznym reprezentują kategorie. Nie należy więc interpretować ich jako klasycznych zmiennych ilościowych, lecz jako zakodowane etykiety kategorii.

Statystyki opisowe:							
	Administrative	Administrative_Duration	Informational	Informational_Duration	ProductRelated	ProductRelated_Duration	BounceRates
count	12330.000000	12330.000000	12330.000000	12330.000000	12330.000000	12330.000000	12330.000000
unique	NaN	NaN	NaN	NaN	NaN	NaN	NaN
top	NaN	NaN	NaN	NaN	NaN	NaN	NaN
freq	NaN	NaN	NaN	NaN	NaN	NaN	NaN
mean	2.315166	80.818611	0.503569	34.472398	31.731468	1194.746220	0.022191
std	3.321784	176.779107	1.270156	140.749294	44.475503	1913.669288	0.048488
min	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
25%	0.000000	0.000000	0.000000	0.000000	7.000000	184.137500	0.000000
50%	1.000000	7.500000	0.000000	0.000000	18.000000	598.936905	0.003112
75%	4.000000	93.256250	0.000000	0.000000	38.000000	1464.157214	0.016813
max	27.000000	3398.750000	24.000000	2549.375000	705.000000	63973.522230	0.200000

Rysunek 6 Podstawowe statystyki opisowe

Na Rysunku 6 znajduje się pierwsza część podstawowych statystyk opisowych dla zmiennych w analizowanym zbiorze danych. Zestawienie obejmuje między innymi liczbę obserwacji, średnią, odchylenie standardowe, wartości minimalne, kwartyle oraz wartości maksymalne dla wybranych zmiennych liczbowych. Statystyki opisowe pozwalają wstępnie ocenić skalę zmiennych, ich zróżnicowanie oraz potencjalne wartości skrajne. Przykładowo zmienna Administrative ma średnią wartość około 2,32, co oznacza, że przeciętnie użytkownicy odwiedzali niewiele stron administracyjnych. Jednocześnie maksymalna wartość tej zmiennej wynosi 27, co wskazuje, że w części sesji użytkownicy wykonywali znacznie większą aktywność w tym obszarze.

Zmienna ProductRelated ma średnią wartość około 31,73, natomiast jej wartość maksymalna wynosi 705. Oznacza to, że część użytkowników odwiedzała bardzo wiele stron produktowych, co może świadczyć o intensywnym przeglądaniu oferty sklepu. Również zmienna ProductRelated_Duration, opisująca czas spędzony na stronach produktowych, charakteryzuje się bardzo dużym zróżnicowaniem. Średnia

wynosi około 1194,75, natomiast wartość maksymalna przekracza 63 000. Może to wskazywać na obecność obserwacji odstających lub bardzo długich sesji użytkowników. Warto również zwrócić uwagę na zmienną BounceRates, której wartości mieszczą się w przedziale od 0 do 0,20. Zmienna ta opisuje udział użytkowników opuszczających stronę bez dalszej interakcji. Niskie wartości tej zmiennej mogą świadczyć o większym zaangażowaniu użytkownika, natomiast wysokie wartości mogą sugerować szybkie opuszczanie serwisu.

PageValues	SpecialDay	Month	OperatingSystems	Browser	Region	TrafficType	VisitorType	Weekend	Revenue
12330.000000	12330.000000	12330	12330.000000	12330.000000	12330.000000	12330.000000	12330	12330	12330
NaN	NaN	10	NaN	NaN	NaN	NaN	3	2	2
NaN	NaN	May	NaN	NaN	NaN	NaN	Returning_Visitor	False	False
NaN	NaN	3364	NaN	NaN	NaN	NaN	10551	9462	10422
5.889258	0.061427	NaN	2.124006	2.357097	3.147364	4.069586	NaN	NaN	NaN
18.568437	0.198917	NaN	0.911325	1.717277	2.401591	4.025169	NaN	NaN	NaN
0.000000	0.000000	NaN	1.000000	1.000000	1.000000	1.000000	NaN	NaN	NaN
0.000000	0.000000	NaN	2.000000	2.000000	1.000000	2.000000	NaN	NaN	NaN
0.000000	0.000000	NaN	2.000000	2.000000	3.000000	2.000000	NaN	NaN	NaN
0.000000	0.000000	NaN	3.000000	2.000000	4.000000	4.000000	NaN	NaN	NaN
361.763742	1.000000	NaN	8.000000	13.000000	9.000000	20.000000	NaN	NaN	NaN

Rysunek 7 Podstawowe statystyki opisowe cd.

Na Rysunku 7 znajduje się druga część tabeli ze statystykami opisowymi. Obejmuje ona między innymi zmienne PageValues, SpecialDay, Month, OperatingSystems, Browser, Region, TrafficType, VisitorType, Weekend oraz Revenue.

Szczególnie istotna z punktu widzenia predykcji zakupu jest zmienna PageValues. Jej średnia wartość wynosi około 5,89, natomiast maksymalna wartość przekracza 361. Wysokie wartości tej zmiennej mogą wskazywać na większą wartość odwiedzanych stron w kontekście potencjalnego zakupu. W dalszej części analizy zmienna ta okazała się jedną z najważniejszych cech wykorzystywanych przez modele klasyfikacyjne. Zmienna SpecialDay przyjmuje wartości od 0 do 1 i opisuje bliskość wizyty względem szczególnego dnia, który może wpływać na decyzje zakupowe, na przykład święta lub wydarzenia promocyjne. Średnia wartość tej zmiennej jest niska, co oznacza, że większość sesji nie była silnie powiązana z tego typu dniami.

W przypadku zmiennych kategoriowych, takich jak Month, VisitorType, Weekend i Revenue, tabela statystyk opisowych prezentuje również informacje charakterystyczne dla danych jakościowych. Przykładowo dla zmiennej Month najczęściej występującą wartością jest May, a dla zmiennej VisitorType najczęściej


pojawia się kategoria `Returning_Visitor`. Oznacza to, że w zbiorze dominują użytkownicy powracający, co może mieć znaczenie przy analizie zachowań zakupowych. Warto także zauważyć, że zmienna docelowa `Revenue` najczęściej przyjmuje wartość `False`. Oznacza to, że większość sesji nie zakończyła się zakupem. Ta obserwacja potwierdza konieczność dokładniejszej analizy rozkładu klas oraz stosowania miar jakości modelu odpornych na problem niezbalansowania danych.

Braki danych w kolumnach:	
	0
Administrative	0
Administrative_Duration	0
Informational	0
Informational_Duration	0
ProductRelated	0
ProductRelated_Duration	0
BounceRates	0
ExitRates	0
PageValues	0
SpecialDay	0
Month	0
OperatingSystems	0
Browser	0
Region	0
TrafficType	0
VisitorType	0
Weekend	0
Revenue	0

Rysunek 8 Analiza braków danych

Na Rysunku 8 znajduje się zestawienie liczby brakujących wartości w poszczególnych kolumnach zbioru danych. Dla każdej zmiennej liczba braków wynosi 0, co oznacza, że analizowany zbiór jest kompletny pod względem wartości pustych. Brak brakujących danych jest istotny dla dalszego procesu przygotowania danych do modelowania. W przypadku występowania braków konieczne byłoby zastosowanie

odpowiednich metod ich obsługi, takich jak usunięcie obserwacji, uzupełnienie średnią, medianą, dominantą lub wykorzystanie bardziej zaawansowanych technik imputacji. W analizowanym przypadku takie działania nie były konieczne. Kompletność danych zwiększa wiarygodność dalszych etapów analizy, ponieważ wszystkie obserwacje mogą zostać wykorzystane przy eksploracji danych oraz trenowaniu modeli. Jednocześnie pozwala ograniczyć ryzyko zniekształcenia wyników, które mogłoby powstać w wyniku nieprawidłowego uzupełniania brakujących wartości.



Liczba duplikatów:
125

Rysunek 9 Liczba duplikatów w zbiorze danych

Na Rysunku 9 znajduje się informacja o liczbie zduplikowanych obserwacji w analizowanym zbiorze danych. Wykryto 125 duplikatów, które zostały następnie usunięte w ramach przygotowania danych do dalszej analizy. Po usunięciu 125 duplikatów liczba obserwacji została zmniejszona z 12 330 do 12 205. Tak przygotowany zbiór danych został następnie wykorzystany w kolejnych etapach analizy, obejmujących eksplorację danych, kodowanie zmiennych, podział na zbiór treningowy i testowy oraz budowę modeli klasyfikacyjnych.

Eksploracyjna analiza danych

Eksploracyjna analiza danych stanowiła jeden z kluczowych etapów projektu, ponieważ pozwoliła na wstępne rozpoznanie struktury analizowanego zbioru, charakteru zmiennych oraz potencjalnych zależności istotnych z punktu widzenia budowy modeli klasyfikacyjnych. Celem tego etapu było nie tylko opisanie danych, lecz także ocena ich przydatności do predykcji intencji zakupowej użytkownika sklepu internetowego.

W pierwszej kolejności przeanalizowano podstawową strukturę zbioru danych, w tym liczbę obserwacji i kolumn, typy zmiennych, występowanie braków danych oraz obecność duplikatów. Następnie skoncentrowano się na zmiennej docelowej Revenue, która określa, czy dana sesja użytkownika zakończyła się zakupem. Analiza rozkładu tej zmiennej była szczególnie istotna, ponieważ pozwoliła ocenić, czy klasy


są zbalansowane, a tym samym czy standardowe miary jakości modeli, takie jak accuracy, będą wystarczające do ich rzetelnej oceny.

W dalszej części eksploracyjnej analizy danych sprawdzono również zależności między wybranymi zmiennymi objaśniającymi a zmienną docelową. Szczególną uwagę zwrócono na cechy opisujące aktywność użytkownika na stronie internetowej, takie jak liczba odwiedzonych stron produktowych, czas spędzony w poszczególnych sekcjach serwisu, wskaźniki odrzuceń i wyjść oraz wartość odwiedzanych stron. Zmienne te mogą mieć istotne znaczenie dla przewidywania czy użytkownik jest realnie zainteresowany zakupem.

Analiza zmiennej docelowej

Zmienną docelową w projekcie jest Revenue, która określa, czy dana sesja użytkownika zakończyła się dokonaniem zakupu. Jest to zmienna binarna, ponieważ przyjmuje jedną z dwóch wartości: True lub False. Wartość True oznacza, że użytkownik dokonał zakupu, natomiast wartość False oznacza, że sesja nie zakończyła się transakcją.


Analiza rozkładu zmiennej docelowej była konieczna, ponieważ w zadaniach klasyfikacji binarnej proporcje między klasami mają bezpośredni wpływ na interpretację wyników modeli. Jeżeli jedna z klas wyraźnie dominuje, model może osiągać wysoką dokładność nawet wtedy, gdy słabo rozpoznaje klasę mniejszościową. W przypadku analizowanego problemu szczególnie ważna jest klasa True, ponieważ to ona odpowiada użytkownikom dokonującym zakupu.



Rysunek 10 Rozkład zmiennej docelowej Revenue

Na Rysunku 10 znajduje się liczbowy oraz procentowy rozkład zmiennej docelowej Revenue po usunięciu duplikatów ze zbioru danych. Z przedstawionych wyników wynika, że w analizowanym zbiorze znajduje się 10 297 sesji, które nie zakończyły się zakupem, oraz 1908 sesji zakończonych zakupem. Oznacza to, że zdecydowana większość obserwacji należy do klasy False. Procentowy rozkład zmiennej Revenue potwierdza występowanie niezbalansowania klas. Sesje niezakończone zakupem stanowią około 84,37% wszystkich obserwacji, natomiast sesje zakończone zakupem stanowią jedynie około 15,63%.

Nierównomierny rozkład klas ma istotne konsekwencje dla dalszego modelowania. W takiej sytuacji sama dokładność klasyfikacji, czyli accuracy, może być niewystarczająca jako główna miara jakości modelu. Model, który często przewiduje klasę większościową, może osiągać pozornie dobry wynik accuracy, mimo że nie rozpoznaje skutecznie użytkowników dokonujących zakupu. Z tego względu w dalszej części projektu wykorzystano również takie miary jak precision, recall oraz F1-score, które pozwalają dokładniej ocenić skuteczność modeli w identyfikacji klasy pozytywnej. Analiza zmiennej docelowej wskazuje zatem, że projekt dotyczy problemu klasyfikacji binarnej z niezbalansowanym rozkładem klas. Jest to ważna informacja metodologiczna, ponieważ uzasadnia zastosowanie stratified split przy podziale danych oraz wykorzystanie walidacji krzyżowej z zachowaniem proporcji klas.




Rysunek 11 Wizualizacja rozkładu zmiennej docelowej Revenue

Na Rysunku 11 przedstawiono wykres słupkowy obrazujący rozkład zmiennej docelowej Revenue, która informuje, czy dana sesja użytkownika zakończyła się dokonaniem zakupu. Na osi poziomej zaprezentowano dwie możliwe wartości zmiennej: False, oznaczającą brak zakupu oraz True, oznaczającą dokonanie zakupu. Oś pionowa przedstawia liczbę obserwacji przypisanych do każdej z tych klas.

Analiza korelacji i wybór zmiennych

W kolejnym etapie eksploracyjnej analizy danych przeprowadzono analizę korelacji pomiędzy zmiennymi numerycznymi. Celem tej części było wstępne rozpoznanie zależności liniowych występujących między cechami oraz określenie, które zmienne mogą mieć największe znaczenie dla przewidywania zmiennej docelowej Revenue. Analiza korelacji pozwala ocenić, czy wzrost wartości jednej zmiennej wiąże się ze wzrostem lub spadkiem wartości innej zmiennej. Zmienna docelowa Revenue miała pierwotnie charakter logiczny, więc została przekształcona do postaci liczbowej. Wartość False, oznaczająca brak zakupu, została potraktowana jako 0, natomiast

wartość True, oznaczająca dokonanie zakupu, jako 1. Takie przekształcenie umożliwiło obliczenie korelacji pomiędzy zmienną docelową a pozostałymi zmiennymi liczbowymi.



Rysunek 12 Macierz korelacji zmiennych numerycznych z uwzględnieniem zmiennej docelowej Revenue

Na Rysunku 12 przedstawiono macierz korelacji dla zmiennych numerycznych wykorzystanych w analizie. Macierz pokazuje siłę i kierunek zależności liniowych pomiędzy poszczególnymi zmiennymi. Wartości korelacji mieszczą się w przedziale od -1 do 1. Wartości dodatnie oznaczają, że wraz ze wzrostem jednej zmiennej zazwyczaj rośnie również druga zmienna. Wartości ujemne oznaczają zależność odwrotną, czyli wzrost jednej zmiennej wiąże się ze spadkiem drugiej. Wartości bliskie 0 wskazują na brak wyraźnej zależności liniowej.

Z punktu widzenia celu projektu najważniejszy jest ostatni wiersz oraz ostatnia kolumna macierzy, które przedstawiają korelacje poszczególnych zmiennych ze zmienną docelową Revenue. Najsilniejszą dodatnią korelację z zakupem wykazuje

zmienna PageValues, dla której współczynnik korelacji wynosi około 0,49. Oznacza to, że wyższa wartość odwiedzanych stron jest wyraźnie powiązana z większym prawdopodobieństwem dokonania zakupu. Jest to zależność zgodna z intuicją biznesową, ponieważ użytkownik odwiedzający strony o większej wartości z perspektywy konwersji może znajdować się bliżej finalizacji transakcji.

Dodatknie, lecz słabsze korelacje ze zmienną Revenue widoczne są również dla zmiennych ProductRelated, ProductRelated_Duration oraz Administrative. Zmienna ProductRelated osiąga korelację około 0,16, natomiast ProductRelated_Duration około 0,15. Oznacza to, że większa liczba odwiedzonych stron produktowych oraz dłuższy czas spędzony na stronach związanych z produktami mogą wiązać się z większą szansą dokonania zakupu. Jest to logiczne, ponieważ użytkownik intensywnie przeglądający produkty prawdopodobnie wykazuje większe zainteresowanie ofertą sklepu.

Ujemne korelacje ze zmienną Revenue widoczne są przede wszystkim dla ExitRates oraz BounceRates. Współczynnik korelacji między ExitRates a Revenue wynosi około -0,20, natomiast między BounceRates a Revenue około -0,15. Oznacza to, że wyższe wartości wskaźników wyjścia i odrzuceń są powiązane z niższym prawdopodobieństwem dokonania zakupu. Interpretacja ta jest zgodna z charakterem tych zmiennych - użytkownicy szybciej opuszczający stronę lub niewykazujący dalszej aktywności rzadziej finalizują transakcję.

Macierz korelacji pokazuje również silne zależności pomiędzy niektórymi zmiennymi objaśniającymi. Szczególnie wysoka dodatnia korelacja występuje między BounceRates i ExitRates, wynosząca około 0,90. Oznacza to, że obie zmienne opisują zbliżony aspekt zachowania użytkownika, związany z opuszczaniem strony. Silna korelacja występuje również między ProductRelated i ProductRelated_Duration, gdzie współczynnik wynosi około 0,86. Jest to zrozumiałe, ponieważ użytkownicy odwiedzający więcej stron produktowych zazwyczaj spędzają więcej czasu w tej części serwisu.

Na podstawie macierzy korelacji można uznać, że największe znaczenie dla dalszej analizy powinny mieć zmienne opisujące wartość odwiedzanych stron, aktywność użytkownika na stronach produktowych oraz wskaźniki opuszczania strony. Do szczególnie istotnych zmiennych należą więc PageValues, ProductRelated, ProductRelated_Duration, BounceRates oraz ExitRates. Zmienne te

zostały następnie uwzględnione w dalszej analizie eksploracyjnej oraz w procesie budowy modeli klasyfikacyjnych.

Korelacja zmiennych numerycznych ze zmienną Revenue:

	Revenue
Revenue	1.000000
PageValues	0.491894
ProductRelated	0.156042
ProductRelated_Duration	0.150077
Administrative	0.136330
Informational	0.093626
Administrative_Duration	0.091768
Informational_Duration	0.069358
Weekend	0.027729
Browser	0.024052
TrafficType	-0.005618
Region	-0.012725
OperatingSystems	-0.014927
SpecialDay	-0.083601
BounceRates	-0.145091
ExitRates	-0.204320

Rysunek 13 Korelacja zmiennych numerycznych ze zmienną docelową Revenue

Na Rysunku 13 przedstawiono wartości współczynników korelacji pomiędzy zmiennymi numerycznymi a zmienną docelową Revenue. Zmienna Revenue została wcześniej przekształcona do postaci liczbowej, gdzie wartość False oznaczono jako 0, natomiast wartość True jako 1. Dzięki temu możliwe było obliczenie zależności liniowych między cechami a informacją o dokonaniu zakupu. Najwyższą dodatnią korelację ze zmienną docelową uzyskała zmienna PageValues, dla której współczynnik korelacji wyniósł około 0,492. Wraz ze wzrostem wartości odwiedzanych stron rośnie prawdopodobieństwo zakończenia sesji zakupem. Jest to wynik zgodny z intuicją biznesową, ponieważ użytkownicy odwiedzający strony o większej wartości z punktu widzenia konwersji częściej mogą znajdować się bliżej decyzji zakupowej. Dodatkowo korelacje ze zmienną Revenue uzyskały również zmienne ProductRelated, ProductRelated_Duration, Administrative, Informational oraz Administrative_Duration. Wartości tych korelacji są jednak wyraźnie niższe niż w przypadku PageValues. Liczba odwiedzonych stron produktowych, czas spędzony na stronach produktowych oraz aktywność użytkownika w innych sekcjach serwisu mogą być powiązane z decyzją zakupową, ale zależność ta ma umiarkowany lub słaby charakter liniowy. Najsilniejsze ujemne korelacje ze zmienną docelową występują dla zmiennych

ExitRates oraz BounceRates. Współczynnik korelacji dla ExitRates wyniósł około -0,204, natomiast dla BounceRates około -0,145. Wyższe wartości wskaźnika wyjść oraz współczynnika odrzuceń są związane z niższym prawdopodobieństwem dokonania zakupu. Użytkownik szybko opuszczający stronę lub niewykazujący dalszej interakcji z serwisem rzadziej finalizuje transakcję. Pozostałe zmienne, takie jak Weekend, Browser, TrafficType, Region, OperatingSystems czy SpecialDay, wykazują bardzo niskie wartości korelacji ze zmienną Revenue. W ujęciu liniowym ich bezpośredni związek z dokonaniem zakupu jest słaby. Nie oznacza to jednak, że zmienne te są całkowicie nieistotne dla modeli klasyfikacyjnych, ponieważ część algorytmów, zwłaszcza modele drzewiaste i zespołowe, może wykrywać zależności nieliniowe oraz interakcje między cechami.


```
Wybrane zmienne numeryczne:  
['PageValues', 'BounceRates', 'ExitRates', 'ProductRelated_Duration']  
Wybrane zmienne kategoryczne:  
['Month', 'VisitorType', 'Weekend']
```

Rysunek 14 Zmienne wybrane do dokładniejszej analizy na podstawie korelacji i interpretacji biznesowej

Na Rysunku 14 przedstawiono zestaw zmiennych wybranych do dokładniejszej analizy na podstawie wyników macierzy korelacji oraz interpretacji biznesowej problemu. Wyróżniono dwie grupy zmiennych: zmienne numeryczne oraz zmienne kategoryczne. Do zmiennych numerycznych wybrano PageValues, BounceRates, ExitRates oraz ProductRelated_Duration. Są to cechy bezpośrednio związane z zachowaniem użytkownika podczas wizyty w sklepie internetowym. Zmienna PageValues została uwzględniona, ponieważ wykazała najwyższą dodatnią korelację ze zmienną docelową Revenue. Jest ona szczególnie istotna z punktu widzenia przewidywania czy sesja zakończy się zakupem. Zmienne BounceRates i ExitRates zostały wybrane ze względu na ich ujemną korelację ze zmienną docelową oraz znaczenie interpretacyjne. Obie cechy opisują zachowanie użytkownika związane z opuszczaniem strony. Wysokie wartości tych wskaźników mogą świadczyć o mniejszym zaangażowaniu użytkownika, niższej jakości sesji lub braku zainteresowania ofertą sklepu. Z tego względu mogą mieć istotne znaczenie przy odróżnianiu sesji zakończonych zakupem od sesji bez zakupu. Zmienna ProductRelated_Duration została uwzględniona jako cecha opisująca czas spędzony na stronach produktowych. Jest ona ważna, ponieważ użytkownicy poświęcający


więcej czasu na przeglądanie produktów mogą wykazywać większe zainteresowanie ofertą sklepu. Nawet jeśli sama korelacja tej zmiennej ze zmienną docelową nie jest bardzo wysoka, jej znaczenie biznesowe uzasadnia dalszą analizę. Do zmiennych kategorycznych wybrano Month, VisitorType oraz Weekend. Zmienna Month pozwala ocenić, czy zachowania zakupowe różnią się w zależności od miesiąca. Może to mieć znaczenie ze względu na sezonowość, promocje lub okresy zwiększonej aktywności zakupowej. Zmienna VisitorType informuje, czy użytkownik jest nowym czy powracającym odwiedzającym, co może wpływać na prawdopodobieństwo zakupu. Zmienna Weekend pozwala sprawdzić, czy sesje odbywające się w weekend różnią się od sesji realizowanych w dni robocze. Dobór tych zmiennych jest uzasadniony zarówno statystycznie, jak i merytorycznie. Wybrane cechy opisują najważniejsze aspekty sesji użytkownika: wartość odwiedzanych stron, zaangażowanie w przeglądanie produktów, skłonność do opuszczania strony oraz kontekst czasowy i typ użytkownika. Z tego względu zostały one wykorzystane w dalszej części eksploracyjnej analizy danych oraz przy interpretacji wyników modeli klasyfikacyjnych.

Wizualizacja wybranych zmiennych



Rysunek 15 Rozkład zmiennej PageValues opisującej wartość odwiedzanych stron z punktu widzenia konwersji


Na Rysunku 15 przedstawiono rozkład zmiennej PageValues, która opisuje wartość odwiedzanych stron z perspektywy potencjalnej konwersji zakupowej. Na osi poziomej znajduje się wartość zmiennej PageValues, natomiast na osi pionowej przedstawiono liczbę obserwacji przypadających na określone przedziały wartości. Rozkład zmiennej PageValues jest wyraźnie prawostronnie skośny. Zdecydowana większość obserwacji koncentruje się przy bardzo niskich wartościach, głównie w pobliżu zera. W wielu sesjach odwiedzane strony nie miały dużej wartości z punktu widzenia późniejszego zakupu lub użytkownik nie dotarł do stron silnie powiązanych z konwersją. Jednocześnie na wykresie widoczny jest długi prawy ogon rozkładu. W zbiorze występuje mniejsza liczba obserwacji o znacznie wyższych wartościach PageValues. Takie obserwacje mogą odpowiadać sesjom użytkowników bardziej zaangażowanych, którzy odwiedzali strony istotne z punktu widzenia decyzji zakupowej. Wcześniejsza analiza korelacji wskazała, że PageValues ma najwyższą dodatnią korelację ze zmienną docelową Revenue, dlatego zmienna ta jest szczególnie ważna dla predykcji zakupu. Widoczna asymetria rozkładu jest istotna z punktu widzenia modelowania. Modele liniowe mogą być wrażliwe na silnie skośne rozkłady oraz wartości skrajne, dlatego w ich przypadku ważne jest odpowiednie skalowanie danych. Z kolei modele drzewiaste, takie jak drzewo decyzyjne i las losowy, zwykle lepiej radzą sobie z tego typu rozkładami, ponieważ dzielą przestrzeń zmiennych na przedziały decyzyjne.



Rysunek 16 Rozkład zmiennej BounceRates opisującej współczynnik odrzuceń użytkowników sklepu internetowego

Na Rysunku 16 przedstawiono rozkład zmiennej BounceRates, która opisuje współczynnik odrzuceń dla sesji użytkowników sklepu internetowego. Na osi poziomej znajduje się wartość współczynnika odrzuceń, natomiast oś pionowa przedstawia liczbę obserwacji. Rozkład zmiennej BounceRates jest silnie skoncentrowany przy wartościach bliskich zeru. W dużej części sesji użytkownicy nie opuszczali strony natychmiast po wejściu lub wykazywali przynajmniej minimalną dalszą aktywność w serwisie. Taki wynik może świadczyć o tym, że znaczna część użytkowników podejmowała jakąś formę interakcji ze sklepem internetowym. Jednocześnie na wykresie widoczny jest prawy ogon rozkładu oraz pojedyncze obserwacje osiągające wyższe wartości, w tym wartości bliskie 0,20. Wyższy poziom BounceRates może oznaczać, że użytkownik szybko opuszczał stronę bez dalszej interakcji. Z punktu widzenia predykcji zakupów jest to istotne, ponieważ wcześniejsza analiza korelacji wykazała ujemny związek między BounceRates a zmienną docelową Revenue. Wzrost współczynnika odrzuceń może być powiązany z niższym prawdopodobieństwem dokonania zakupu. Zmienna BounceRates ma ważne znaczenie interpretacyjne, ponieważ opisuje jakość sesji użytkownika. Niskie wartości tej zmiennej mogą sugerować większe zaangażowanie użytkownika, natomiast wysokie wartości mogą wskazywać na brak zainteresowania ofertą, nieadekwatność


strony wejścia lub szybkie opuszczenie serwisu. Dlatego zmienna ta została uwzględniona w dalszej analizie i modelowaniu.



Rysunek 17 Rozkład zmiennej ExitRates opisującej współczynnik wyjść ze strony internetowej

Na Rysunku 17 przedstawiono rozkład zmiennej ExitRates, która opisuje współczynnik wyjść ze strony internetowej. Zmienna ta informuje, jak często dana strona była ostatnią stroną odwiedzoną przez użytkownika w trakcie sesji. Na osi poziomej zaprezentowano wartości współczynnika ExitRates, natomiast na osi pionowej liczbę obserwacji przypadających na poszczególne przedziały. Rozkład zmiennej jest wyraźnie prawostronnie skośny. Największa koncentracja obserwacji występuje przy niskich wartościach, zwłaszcza w przedziale od około 0,01 do 0,04. Taki kształt rozkładu wskazuje, że w wielu sesjach współczynnik wyjść był relatywnie niski, co może świadczyć o tym, że użytkownicy kontynuowali przeglądanie serwisu, zamiast kończyć wizytę po odwiedzeniu pojedynczej strony. Jednocześnie na wykresie widoczny jest długi prawy ogon rozkładu oraz wyraźna grupa obserwacji przy wartości bliskiej 0,20. Wysokie wartości ExitRates są istotne interpretacyjnie, ponieważ mogą wskazywać na sesje, w których użytkownik kończył wizytę bez dalszej interakcji lub bez przejścia do kolejnych etapów ścieżki zakupowej. W kontekście sklepu internetowego może to sugerować niższe zaangażowanie użytkownika,


problem z atrakcyjnością treści, niedopasowanie oferty albo naturalne zakończenie przeglądania strony. Zmienna `ExitRates` jest ważna z punktu widzenia predykcji zakupu, ponieważ wcześniejsza analiza korelacji wykazała jej ujemny związek ze zmienną docelową `Revenue`. Im wyższy współczynnik wyjść, tym mniejsze prawdopodobieństwo, że sesja zakończy się zakupem. Warto jednak podkreślić, że interpretacja tej zmiennej powinna być ostrożna. Samo opuszczenie strony nie zawsze świadczy o negatywnym zachowaniu użytkownika - może wynikać również z zakończenia poszukiwania informacji lub porównywania produktów. W dalszym modelowaniu `ExitRates` może pomagać algorytmom w rozpoznawaniu sesji o niższym potencjale zakupowym. Szczególnie modele drzewiaste i zespołowe mogą wykorzystać tę zmienną do tworzenia reguł decyzyjnych, które odróżniają użytkowników aktywnie eksplorujących sklep od tych, którzy szybciej kończą wizytę.



Rysunek 18 Rozkład zmiennej `ProductRelated_Duration` przedstawiającej czas spędzony na stronach produktowych


Na Rysunku 18 przedstawiono rozkład zmiennej `ProductRelated_Duration`, która określa czas spędzony przez użytkownika na stronach związanych z produktami. Na osi poziomej znajduje się czas trwania aktywności w sekcji produktowej, natomiast oś pionowa prezentuje liczbę obserwacji. Rozkład tej zmiennej jest silnie

prawostronnie skośny. Zdecydowana większość sesji skupia się przy niskich wartościach czasu, co sugeruje, że wielu użytkowników spędzało stosunkowo krótki czas na stronach produktowych. Na wykresie widoczny jest również bardzo długi prawy ogon, sięgający wartości powyżej 60 000. Tak wysokie wartości wskazują na obecność sesji nietypowo długich. Mogą one wynikać z rzeczywiście intensywnego przeglądania produktów, ale także z sytuacji technicznych, na przykład pozostawienia otwartej karty przeglądarki bez aktywności użytkownika. Z perspektywy biznesowej ProductRelated_Duration jest jedną z bardziej intuicyjnych zmiennych w analizie. Czas spędzony na stronach produktowych może świadczyć o zainteresowaniu ofertą sklepu, porównywaniu produktów lub analizowaniu szczegółów przed zakupem. Jednocześnie sam długi czas trwania sesji nie gwarantuje dokonania transakcji, dlatego zmienna ta powinna być analizowana łącznie z innymi cechami, takimi jak PageValues, ExitRates, BounceRates czy liczba odwiedzonych stron produktowych. Kształt rozkładu ma także znaczenie techniczne. Ze względu na dużą asymetrię i obecność wartości skrajnych modele liniowe mogą wymagać standaryzacji lub dodatkowego przekształcenia tej zmiennej.



Rysunek 19 Rozkład zmiennej PageValues względem zmiennej docelowej Revenue


Na Rysunku 19 przedstawiono wykres pudełkowy zmiennej PageValues w podziale na dwie klasy zmiennej docelowej Revenue: sesje niezakończone zakupem (False) oraz sesje zakończone zakupem (True). Wykres pozwala porównać rozkład wartości odwiedzanych stron pomiędzy użytkownikami, którzy dokonali zakupu, a użytkownikami, którzy nie sfinalizowali transakcji. Dla klasy False wartości zmiennej PageValues są silnie skoncentrowane w pobliżu zera. Mediana tej zmiennej jest bardzo niska, a główna część rozkładu znajduje się blisko dolnej granicy skali. Widoczna jest jednak duża liczba obserwacji odstających, co wskazuje, że część sesji bez zakupu również obejmowała strony o pewnej wartości konwersyjnej. Nie zmienia to jednak ogólnego obrazu: wśród użytkowników niedokonujących zakupu dominują niskie wartości PageValues. W przypadku klasy True rozkład jest wyraźnie przesunięty ku wyższym wartościom. Mediana oraz rozstęp międzykwartyłowy są większe niż dla klasy False, co sugeruje, że użytkownicy dokonujący zakupu częściej odwiedzali strony o większej wartości z punktu widzenia konwersji. Na wykresie widoczne są także liczne obserwacje odstające, w tym bardzo wysokie wartości przekraczające 300. Takie przypadki mogą odpowiadać sesjom szczególnie wartościowym, w których użytkownik intensywnie poruszał się po stronach silnie powiązanych z dokonaniem zakupu. Porównanie obu klas wskazuje, że PageValues jest jedną z najbardziej różnicujących zmiennych w analizowanym zbiorze. Wyższe wartości tej cechy częściej występują w grupie sesji zakończonych zakupem. Wynik ten jest spójny z wcześniejszą analizą korelacji, w której PageValues uzyskała najwyższą dodatnią korelację ze zmienną docelową Revenue.



Rysunek 20 Rozkład zmiennej BounceRates względem zmiennej docelowej Revenue

Na Rysunku 20 przedstawiono wykres pudełkowy zmiennej BounceRates w zależności od wartości zmiennej docelowej Revenue. Zmienna BounceRates opisuje współczynnik odrzuceń, czyli sytuacje, w których użytkownik opuszcza stronę bez dalszej interakcji z serwisem. Dla sesji niezakończonych zakupem (False) rozkład BounceRates jest bardziej rozproszony. Występuje większa liczba obserwacji odstających oraz wyższe wartości maksymalne. Widoczne są przypadki, w których współczynnik odrzuceń osiąga wartości bliskie 0,20. Taki układ sugeruje, że w grupie użytkowników niedokonujących zakupu częściej pojawiały się sesje o wyższym poziomie odrzuceń, czyli sesje krótkie lub mało angażujące. Dla sesji zakończonych zakupem (True) wartości BounceRates są niższe i bardziej skoncentrowane przy zerze. Rozstęp międzykwartylowy jest mniejszy, a większość obserwacji mieści się w niskim zakresie wartości. Wskazuje to, że użytkownicy dokonujący zakupu rzadziej opuszczali stronę natychmiast po wejściu i częściej podejmowali dalszą aktywność w serwisie. Wykres potwierdza ujemny charakter zależności między BounceRates a prawdopodobieństwem zakupu. Wyższy współczynnik odrzuceń jest bardziej charakterystyczny dla sesji niezakończonych transakcją. Z perspektywy biznesowej zmienna ta może być traktowana jako wskaźnik jakości sesji: niskie wartości mogą


świadczą o większym zaangażowaniu użytkownika, natomiast wysokie wartości mogą wskazywać na brak zainteresowania ofertą lub szybkie przerwanie wizyty.



Rysunek 21 Rozkład zmiennej ExitRates względem zmiennej docelowej Revenue

Na Rysunku 21 przedstawiono wykres pudełkowy zmiennej ExitRates w podziale na sesje zakończone i niezakończone zakupem. Zmienna ExitRates opisuje współczynnik wyjść, czyli częstość, z jaką użytkownik kończył wizytę na danej stronie. Dla klasy False wartości ExitRates są wyraźnie wyższe niż dla klasy True. Mediana w grupie sesji niezakończonych zakupem znajduje się na wyższym poziomie, a rozstęp międzykwartylowy jest szerszy. Taki rozkład wskazuje na większą zmienność i częstsze występowanie podwyższonych współczynników wyjść wśród użytkowników, którzy nie dokonali zakupu. Dla klasy True pudełko znajduje się niżej, a większość obserwacji koncentruje się przy niższych wartościach ExitRates. Sesje zakończone zakupem charakteryzują się więc niższą skłonnością do opuszczania strony na wcześniejszych etapach wizyty. W grupie tej również występują obserwacje odstające, jednak główna część rozkładu pozostaje niżej niż w przypadku klasy False. Wykres dobrze ilustruje interpretację uzyskaną wcześniej w analizie korelacji. ExitRates ma ujemny związek ze zmienną Revenue, ponieważ wyższe wartości współczynnika wyjść częściej pojawiają się w sesjach bez zakupu. Zmienna ta może być więc przydatna w modelowaniu, ponieważ pomaga odróżniać użytkowników

kontynuujących ścieżkę zakupową od tych, którzy szybciej opuszczają sklep internetowy.




Rysunek 22 Rozkład zmiennej *ProductRelated_Duration* względem zmiennej docelowej *Revenue*

Na Rysunku 22 przedstawiono wykres pudełkowy zmiennej *ProductRelated_Duration* w zależności od wartości zmiennej docelowej *Revenue*. Zmienna ta informuje o czasie spędzonym przez użytkownika na stronach produktowych sklepu internetowego. W obu grupach widoczna jest silna asymetria rozkładu oraz liczne obserwacje odstające. Większość sesji koncentruje się przy relatywnie niskich wartościach czasu, natomiast pojedyncze obserwacje osiągają bardzo wysokie wartości. W grupie *False* pojawiają się szczególnie skrajne przypadki, w tym obserwacje przekraczające 60 000. Tak wysokie wartości mogą wynikać z bardzo długiego przeglądania produktów, ale mogą też być efektem pozostawienia otwartej strony bez aktywnej interakcji użytkownika. Dla klasy *True* rozkład *ProductRelated_Duration* jest nieco przesunięty ku wyższym wartościom w głównej części rozkładu. Sugeruje to, że użytkownicy dokonujący zakupu spędzali przeciętnie więcej czasu na stronach produktowych niż użytkownicy, którzy nie sfinalizowali transakcji. Jest to zgodne z intuicją biznesową, ponieważ dłuższe przeglądanie produktów może świadczyć o większym zainteresowaniu ofertą i bardziej zaawansowanym etapie procesu decyzyjnego. Jednocześnie sama długość czasu

spędzonego na stronach produktowych nie przesądza o zakupie. W grupie False również występuje wiele wysokich wartości, co pokazuje, że długie przeglądanie produktów może kończyć się zarówno zakupem, jak i rezygnacją. Zmienna `ProductRelated_Duration` powinna być zatem interpretowana łącznie z innymi cechami, na przykład `PageValues`, `ExitRates`, `BounceRates` oraz liczbą odwiedzonych stron produktowych.


Histogramy i wykresy pudełkowe zostały wykorzystane w celu dokładniejszego poznania rozkładów wybranych zmiennych numerycznych oraz porównania ich wartości między użytkownikami, którzy dokonali zakupu, a użytkownikami, którzy nie zakończyli sesji transakcją. Histogramy pozwalają ocenić kształt rozkładu zmiennych, ich asymetrię oraz obecność wartości skrajnych, natomiast wykresy pudełkowe umożliwiają bezpośrednie porównanie median, rozstępów międzykwartylowych i obserwacji odstających w grupach `Revenue = True` oraz `Revenue = False`. Po analizie zmiennych numerycznych przeprowadzono również analizę zmiennych kategorycznych: `Month`, `VisitorType` oraz `Weekend`. Celem tej części było sprawdzenie czy liczba sesji zakończonych zakupem różni się w zależności od miesiąca wizyty, typu użytkownika oraz tego, czy sesja odbyła się w weekend. Zmienne kategoryczne są istotne, ponieważ pozwalają uwzględnić kontekst zachowania użytkownika, którego nie da się w pełni opisać wyłącznie za pomocą zmiennych liczbowych.



Rysunek 23 Liczba sesji w poszczególnych miesiącach z podziałem na zmienną docelową Revenue

Na Rysunku 23 przedstawiono liczbę sesji użytkowników w poszczególnych miesiącach z podziałem na wartość zmiennej docelowej Revenue. Kolorem niebieskim oznaczono sesje, które nie zakończyły się zakupem, natomiast kolorem pomarańczowym oznaczono sesje zakończone dokonaniem zakupu. Oś pozioma przedstawia miesiące, w których odnotowano wizyty użytkowników, a oś pionowa prezentuje liczbę obserwacji. Z wykresu wynika, że liczba sesji nie jest równomiernie rozłożona pomiędzy miesiącami. Najwięcej obserwacji występuje w maju oraz listopadzie, a relatywnie dużo sesji odnotowano również w marcu i grudniu. Może to wskazywać na sezonowość aktywności użytkowników sklepu internetowego, wynikającą na przykład z okresów promocyjnych, zmian popytu lub większej aktywności zakupowej w określonych częściach roku. W każdym miesiącu liczba sesji niezakończonych zakupem jest wyższa niż liczba sesji zakończonych zakupem. Jest to zgodne z wcześniejszą analizą zmiennej docelowej Revenue, która wykazała, że zbiór danych jest niezbalansowany, a większość użytkowników nie dokonuje zakupu. Szczególnie widoczne jest to w maju, gdzie liczba sesji bez zakupu jest bardzo wysoka w porównaniu z liczbą transakcji. Największą liczbę sesji zakończonych zakupem można zauważyć w listopadzie. Może to sugerować, że ten miesiąc ma szczególne znaczenie z punktu widzenia sprzedaży internetowej, prawdopodobnie ze względu na sezon zakupowy, promocje lub wzmożoną aktywność konsumentów. Wysoka liczba


zakupów w listopadzie pokazuje, że zmienna Month może dostarczać modelom informacji o sezonowym charakterze decyzji zakupowych. Wykres potwierdza, że miesiąc wizyty może być istotną zmienną kontekstową w analizie intencji zakupowej. Nie opisuje on bezpośrednio zachowania użytkownika w trakcie sesji, ale pozwala uwzględnić czasowy aspekt aktywności zakupowej. Z tego względu zmienna Month została uwzględniona w dalszym procesie przygotowania danych i modelowania.



Rysunek 24 Liczba sesji według typu użytkownika z podziałem na zmienną docelową Revenue

Na Rysunku 24 przedstawiono liczbę sesji użytkowników według typu odwiedzającego, z podziałem na sesje zakończone zakupem oraz sesje niezakończone zakupem. Zmienna VisitorType informuje, czy użytkownik był użytkownikiem powracającym (Returning_Visitor), nowym użytkownikiem (New_Visitor) lub należał do kategorii Other. Na wykresie wyraźnie widać, że największą grupę stanowią użytkownicy powracający. Zarówno wśród sesji zakończonych zakupem, jak i sesji bez zakupu, kategoria Returning_Visitor dominuje liczebnie nad pozostałymi typami użytkowników. Jest to ważna informacja, ponieważ pokazuje, że analizowany sklep internetowy był często odwiedzany przez osoby, które miały już wcześniejszy kontakt z serwisem. W grupie użytkowników powracających

liczba sesji niezakończonych zakupem jest zdecydowanie wyższa niż liczba sesji zakończonych transakcją. Wynik ten jest zgodny z ogólnym rozkładem zmiennej Revenue, ponieważ w całym zbiorze danych dominują sesje bez zakupu. Jednocześnie liczba zakupów w tej grupie jest większa niż wśród nowych użytkowników, co może wynikać z większej liczby samych wizyt powracających użytkowników. W przypadku kategorii New_Visitor liczba obserwacji jest wyraźnie niższa niż dla użytkowników powracających. Nowi użytkownicy również częściej nie dokonują zakupu niż dokonują zakupu, jednak różnica między klasami jest mniej spektakularna liczebnie ze względu na mniejszą wielkość tej grupy. Kategoria Other ma marginalne znaczenie w zbiorze danych, ponieważ obejmuje bardzo małą liczbę obserwacji. Z punktu widzenia modelowania zmienna VisitorType może dostarczać istotnej informacji kontekstowej. Typ użytkownika może wpływać na prawdopodobieństwo zakupu, ponieważ użytkownicy powracający mogą lepiej znać ofertę sklepu, proces zakupowy oraz układ strony. Nowi użytkownicy mogą natomiast częściej znajdować się na wcześniejszym etapie ścieżki zakupowej, czyli dopiero porównywać ofertę lub poznawać sklep. Zmienna ta została więc zasadnie uwzględniona w dalszym przygotowaniu danych do modelowania.



Rysunek 25 Liczba sesji w dni robocze i weekendy z podziałem na zmienną docelową Revenue

Na Rysunku 25 przedstawiono liczbę sesji użytkowników w zależności od tego, czy wizyta odbyła się w weekend, z podziałem na wartość zmiennej docelowej Revenue. Zmienna Weekend przyjmuje wartość False, gdy sesja odbyła się poza weekendem oraz True, gdy sesja miała miejsce w weekend. Z wykresu wynika, że większa część sesji odbywała się poza weekendem. Dla wartości Weekend = False liczba obserwacji jest zdecydowanie wyższa zarówno w grupie sesji niezakończonych zakupem, jak i w grupie sesji zakończonych zakupem. Może to wynikać z większej ogólnej aktywności użytkowników w dni robocze lub z większej liczby dni roboczych w porównaniu z dniami weekendowymi. W obu kategoriach zmiennej Weekend dominują sesje niezakończone zakupem. Jest to zgodne z wcześniejszą analizą rozkładu zmiennej Revenue, która wskazała na wyraźną przewagę klasy False. Zarówno w dni robocze, jak i w weekendy większość wizyt w sklepie internetowym nie prowadziła bezpośrednio do finalizacji transakcji. Warto jednak zauważyć, że sesje weekendowe również generują zakupy, mimo że ich liczba jest niższa w ujęciu bezwzględnym. Sama liczba transakcji jest mniejsza głównie dlatego, że sesji weekendowych jest mniej. Zmienna Weekend ma znaczenie kontekstowe, ponieważ pozwala uwzględnić potencjalne różnice w zachowaniu zakupowym użytkowników w zależności od dnia tygodnia. W praktyce użytkownicy mogą inaczej korzystać ze sklepu internetowego w dni robocze, a inaczej w weekendy. Różnić może się czas poświęcony na przeglądanie produktów, motywacja zakupowa oraz sposób podejmowania decyzji.

Przygotowanie danych do modelowania

Przed rozpoczęciem budowy modeli klasyfikacyjnych dane zostały odpowiednio przygotowane, tak aby mogły zostać poprawnie wykorzystane przez algorytmy uczenia maszynowego. Etap ten obejmował przekształcenie zmiennych kategoriowych do postaci liczbowej, zamianę zmiennej docelowej Revenue na wartości binarne, wydzielenie zbioru cech objaśniających oraz zmiennej objaśnianej, a następnie podział danych na zbiór treningowy i testowy. Zastosowano również standaryzację zmiennych, aby sprowadzić je do porównywalnej skali.

```

#Kodowanie zmiennych kategorycznych
df_encoded = pd.get_dummies(df, drop_first=True)

# Zamiana Revenue na 0/1
if df_encoded['Revenue'].dtype == 'bool':
    df_encoded['Revenue'] = df_encoded['Revenue'].astype(int)

X = df_encoded.drop('Revenue', axis=1)
y = df_encoded['Revenue']

print('Rozmiar X:', X.shape)
print('Rozmiar y:', y.shape)

X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.2,
    random_state=42,
    stratify=y
)

scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

```

Rysunek 26 Przygotowanie danych do modelowania: kodowanie zmiennych, podział na zbiór treningowy i testowy oraz standaryzacja cech

Na Rysunku 26 przedstawiono fragment kodu odpowiedzialny za przygotowanie danych do modelowania. Pierwszym krokiem było zakodowanie zmiennych kategorycznych za pomocą funkcji `pd.get_dummies()`. Funkcja ta przekształca zmienne jakościowe na zestaw zmiennych zero-jedynkowych, które mogą być wykorzystane przez modele uczenia maszynowego. Parametr `drop_first=True` powoduje usunięcie pierwszej kategorii referencyjnej, co ogranicza nadmiarowość informacji i zmniejsza ryzyko współliniowości między zmiennymi.


Następnie zmienna docelowa `Revenue` została przekształcona z typu logicznego na postać liczbową. Wartość `False`, oznaczająca brak zakupu, została zakodowana jako 0, natomiast wartość `True`, oznaczająca dokonanie zakupu, jako 1. Takie przekształcenie było konieczne, ponieważ modele klasyfikacyjne wymagają jednoznacznie określonej zmiennej docelowej w formacie liczbowym.

W kolejnym kroku utworzono macierz cech `X` oraz wektor zmiennej docelowej `y`. Z macierzy `X` usunięto kolumnę `Revenue`, ponieważ jest ona zmienną przewidywaną, a nie predyktorem. Do wektora `y` przypisano natomiast samą zmienną `Revenue`. Dzięki

temu dane zostały rozdzielone na część wejściową, wykorzystywaną do uczenia modeli oraz część wyjściową, którą modele mają przewidywać.

Następnie zastosowano podział danych na zbiór treningowy i testowy za pomocą funkcji `train_test_split()`. Zbiór testowy stanowił 20% wszystkich obserwacji, natomiast pozostałe 80% wykorzystano do trenowania modeli. Parametr `random_state=42` zapewnia powtarzalność wyników, ponieważ przy każdym uruchomieniu kodu podział danych będzie taki sam. Dodatkowo zastosowano parametr `stratify=y`, który zachowuje proporcje klas zmiennej `Revenue` w zbiorze treningowym i testowym. Jest to szczególnie istotne, ponieważ analizowany zbiór danych jest niezbalansowany, tzn. sesji zakończonych zakupem jest znacznie mniej niż sesji bez zakupu.

Ostatnim etapem widocznym na rysunku była standaryzacja zmiennych za pomocą `StandardScaler`. Standaryzator został najpierw dopasowany do zbioru treningowego przy użyciu metody `fit_transform()`, a następnie zastosowany do zbioru testowego za pomocą metody `transform()`. Informacje ze zbioru testowego nie są wykorzystywane przy dopasowywaniu skali. Pozwala to uniknąć przecieku danych i zapewnia bardziej rzetelną ocenę jakości modeli.



```
Rozmiar X: (12205, 26)
Rozmiar y: (12205,)
```

Rysunek 27 Rozmiar macierzy cech X oraz wektora zmiennej docelowej y po kodowaniu zmiennych kategorycznych

Na Rysunku 27 przedstawiono wynik działania kodu, który sprawdza rozmiar macierzy cech X oraz wektora zmiennej docelowej y po wcześniejszym przygotowaniu danych do modelowania. Wynik `Rozmiar X: (12205, 26)` oznacza, że po usunięciu duplikatów oraz zakodowaniu zmiennych kategorycznych zbiór cech objaśniających zawiera 12 205 obserwacji oraz 26 kolumn. Każdy wiersz odpowiada jednej sesji użytkownika sklepu internetowego, natomiast każda kolumna reprezentuje jedną cechę wykorzystywaną przez modele klasyfikacyjne.

Po zastosowaniu funkcji `get_dummies()` liczba kolumn wzrosła w porównaniu z pierwotnym zbiorem danych. Początkowo zbiór zawierał 18 kolumn, jednak po usunięciu zmiennej docelowej `Revenue` i zakodowaniu zmiennych kategorycznych

liczba cech wejściowych wyniosła 26. Stało się tak, ponieważ zmienne kategoryczne, takie jak Month, VisitorType czy Weekend, zostały przekształcone na zestaw zmiennych zero-jedynkowych. Przykładowo zmienna Month została rozbita na osobne kolumny odpowiadające poszczególnym miesiącom, takie jak Month_Feb, Month_Mar czy Month_May.

Budowa modeli klasyfikacyjnych

Po zakończeniu etapu przygotowania danych przystąpiono do budowy modeli klasyfikacyjnych. Celem modelowania było przewidzenie wartości zmiennej docelowej Revenue, czyli określenie, czy dana sesja użytkownika sklepu internetowego zakończyła się dokonaniem zakupu. Problem miał charakter klasyfikacji binarnej, ponieważ zmienna Revenue przyjmowała dwie wartości: 0, oznaczającą brak zakupu, oraz 1, oznaczającą zakup.

Do budowy modeli wykorzystano dane po wcześniejszym oczyszczeniu, zakodowaniu zmiennych kategorycznych, podziale na zbiór treningowy i testowy oraz standaryzacji cech. Zbiór testowy obejmował 2441 obserwacji, w tym 2059 przypadków klasy 0 oraz 382 przypadki klasy 1.

W projekcie porównano cztery modele klasyfikacyjne:


- regresję logistyczną,
- drzewo decyzyjne,
- las losowy,
- algorytm KNN.

Modele zostały ocenione za pomocą kilku miar jakości: precision, recall, f1-score, accuracy oraz macierzy pomyłek. Zastosowanie wielu miar było konieczne, ponieważ w przypadku niezbalansowanych danych sama dokładność klasyfikacji może prowadzić do niepełnej oceny modelu. Szczególnie ważna była jakość rozpoznawania klasy 1, czyli sesji zakończonych zakupem.

Miara precision informuje, jaka część obserwacji zaklasyfikowanych przez model jako zakup rzeczywiście była zakupem. Miara recall pokazuje, jaką część wszystkich rzeczywistych zakupów model poprawnie wykrył. F1-score jest średnią harmoniczną precyzji i czułości, dlatego dobrze sprawdza się wtedy, gdy potrzebna jest równowaga między unikaniem fałszywych alarmów a wykrywaniem faktycznych przypadków klasy

pozytywnej. Macierz pomyłek pozwala natomiast przeanalizować konkretne liczby poprawnych i błędnych klasyfikacji.

1. Regresja logistyczna



Rysunek 28 Raport klasyfikacji i macierz pomyłek dla modelu regresji logistycznej

Na Rysunku 28 przedstawiono wyniki klasyfikacji dla modelu regresji logistycznej oraz odpowiadającą im macierz pomyłek. Raport klasyfikacyjny pokazuje, że model osiągnął ogólną dokładność równą 0,89. Dla klasy 0, czyli sesji niezakończonych zakupem, model uzyskał bardzo dobre wyniki: precision wyniosło 0,90, recall 0,98, a f1-score 0,94. Wskazuje to, że regresja logistyczna bardzo dobrze rozpoznawała użytkowników, którzy nie dokonali zakupu.


Znacznie słabsze wyniki uzyskano jednak dla klasy 1, czyli sesji zakończonych zakupem. Dla tej klasy precision wyniosło 0,77, co sugeruje, że jeżeli model przewidywał zakup, to stosunkowo często była to trafna predykcja. Problemem był jednak niski recall, który wyniósł 0,42. Oznacza to, że model wykrył jedynie około 42% rzeczywistych przypadków zakupu. W rezultacie f1-score dla klasy pozytywnej wyniósł 0,54.

Macierz pomyłek pokazuje szczegółowy rozkład predykcji. Model poprawnie zaklasyfikował 2012 sesji bez zakupu jako klasę 0 oraz 159 sesji zakończonych zakupem jako klasę 1. Jednocześnie 47 sesji bez zakupu zostało błędnie

przewidywanych jako zakup, a 223 rzeczywiste zakupy zostały zaklasyfikowane jako brak zakupu. Największym ograniczeniem regresji logistycznej jest więc duża liczba fałszywie negatywnych predykcji dla klasy zakupowej.

Z perspektywy biznesowej taki model może być zbyt ostrożny w przewidywaniu zakupów. Rzadko klasyfikuje użytkowników jako potencjalnych kupujących, przez co pomija znaczną część rzeczywistych klientów dokonujących zakupu. Mimo wysokiej ogólnej dokładności model nie jest optymalny, jeżeli głównym celem jest identyfikacja użytkowników o wysokim prawdopodobieństwie konwersji.

2. Drzewo decyzyjne



Rysunek 29 Raport klasyfikacji i macierz pomyłek dla modelu drzewa decyzyjnego

Na Rysunku 29 przedstawiono raport klasyfikacyjny oraz macierz pomyłek dla modelu drzewa decyzyjnego. Model osiągnął dokładność równą 0,86, czyli niższą niż regresja logistyczna. Dla klasy 0 uzyskano precision, recall oraz f1-score na poziomie 0,92. Wyniki te pokazują, że drzewo decyzyjne dobrze identyfikowało sesje niezakończone zakupem.


W przypadku klasy 1 model uzyskał bardziej zrównoważone wyniki niż regresja logistyczna. Zarówno precision, jak i recall wyniosły 0,55, a f1-score również osiągnął

wartość 0,55. W porównaniu z regresją logistyczną drzewo decyzyjne wykryło większą część rzeczywistych zakupów, ale kosztem większej liczby błędnych przewidywań klasy pozytywnej. Innymi słowy, model był bardziej skłonny do klasyfikowania sesji jako zakupowych, ale jego predykcje były mniej precyzyjne.

Macierz pomyłek potwierdza tę interpretację. Model poprawnie zaklasyfikował 1887 sesji bez zakupu oraz 212 sesji zakończonych zakupem. Jednocześnie popełnił 172 błędy fałszywie pozytywne, czyli przypadki, w których sesje bez zakupu zostały przewidziane jako zakup. Wystąpiło także 170 błędów fałszywie negatywnych, czyli rzeczywistych zakupów sklasyfikowanych jako brak zakupu.

Wyniki drzewa decyzyjnego pokazują, że model lepiej niż regresja logistyczna radził sobie z wykrywaniem klasy pozytywnej, ale był mniej stabilny i mniej precyzyjny. Może to wynikać z charakteru drzewa decyzyjnego, które tworzy ostre podziały danych i może reagować na lokalne zależności występujące w zbiorze treningowym.

3. Las losowy (Random Forest)



Rysunek 30 Raport klasyfikacji i macierz pomyłek dla modelu lasu losowego

Na Rysunku 30 przedstawiono wyniki klasyfikacji dla modelu lasu losowego. Model osiągnął najwyższą dokładność spośród zaprezentowanych modeli, równą 0,91. Dla


klasy 0 uzyskał bardzo dobre wyniki: precision wyniosło 0,93, recall 0,97, a f1-score 0,95. Oznacza to, że model bardzo skutecznie rozpoznawał sesje niezakończone zakupem.

Najważniejsza jest jednak jakość predykcji dla klasy 1. W przypadku sesji zakończonych zakupem las losowy uzyskał precision na poziomie 0,77, recall równy 0,59 oraz f1-score równy 0,67. Są to najlepsze wyniki dla klasy pozytywnej spośród analizowanych modeli. Model zachował wysoką precyzję, a jednocześnie wykrył większą część rzeczywistych zakupów niż regresja logistyczna i KNN.

Macierz pomyłek pokazuje, że las losowy poprawnie sklasyfikował 1992 sesje bez zakupu oraz 225 sesji zakończonych zakupem. Liczba fałszywie pozytywnych predykcji wyniosła 67, natomiast liczba fałszywie negatywnych predykcji wyniosła 157. W porównaniu z regresją logistyczną model wykrył więcej rzeczywistych zakupów, a jednocześnie utrzymał umiarkowaną liczbę błędnych wskazań klasy pozytywnej.

Wyniki wskazują, że las losowy najlepiej równoważył precyzję i czułość dla klasy zakupowej. Jest to szczególnie istotne w analizowanym problemie, ponieważ głównym celem modelu nie jest wyłącznie poprawne przewidywanie braku zakupu, ale przede wszystkim identyfikacja użytkowników, którzy mogą dokonać transakcji. Z tego względu model lasu losowego można uznać za najbardziej efektywny spośród analizowanych rozwiązań na etapie testowym.

4. KNN



Rysunek 31 Raport klasyfikacji i macierz pomyłek dla modelu KNN

Na Rysunku 31 przedstawiono raport klasyfikacji oraz macierz pomyłek dla modelu KNN. Model osiągnął ogólną dokładność równą 0,87. Dla klasy 0 uzyskał precision równy 0,89, recall równy 0,97 oraz f1-score równy 0,93. Podobnie jak pozostałe modele, KNN dobrze rozpoznawał klasę dominującą, czyli sesje bez zakupu.

W przypadku klasy 1 wyniki były słabsze. Precision wyniosło 0,67, co wskazuje, że część przewidywań zakupu była trafna, ale model nie był tak precyzyjny jak regresja logistyczna czy las losowy. Recall wyniósł 0,38, więc KNN wykrył mniej niż połowę rzeczywistych zakupów. W rezultacie f1-score dla klasy pozytywnej osiągnął wartość 0,48, najniższą spośród analizowanych modeli.

Macierz pomyłek pokazuje, że model poprawnie sklasyfikował 1987 sesji bez zakupu oraz 145 sesji zakończonych zakupem. Błędnie przewidział 72 sesje bez zakupu jako zakupy oraz nie wykrył 237 rzeczywistych zakupów. Największym problemem modelu KNN jest więc wysoka liczba fałszywie negatywnych przypadków, czyli użytkowników, którzy dokonali zakupu, ale zostali sklasyfikowani jako osoby niedokonujące transakcji.

Wyniki modelu KNN sugerują, że w analizowanym zbiorze danych podobieństwo obserwacji mierzone w przestrzeni cech nie wystarczyło do skutecznego rozpoznawania klasy zakupowej. Może to wynikać z niezbalansowania danych, złożonego charakteru zależności między zmiennymi lub obecności cech o nietypowych rozkładach. Mimo zastosowania standaryzacji KNN okazał się mniej skuteczny niż las losowy oraz drzewo decyzyjne w identyfikacji sesji zakończonych zakupem.

Na podstawie uzyskanych wyników można stwierdzić, że wszystkie modele dobrze rozpoznawały klasę większościową, czyli sesje niezakończone zakupem. Wynika to częściowo z niezbalansowanego charakteru zbioru danych, w którym zdecydowana większość obserwacji należy do klasy 0. Różnice między modelami są jednak wyraźne przy analizie klasy 1, czyli sesji zakończonych zakupem.

Regresja logistyczna osiągnęła wysoką ogólną dokładność i dobrą precyzję dla klasy zakupowej, ale miała niski recall, co oznacza, że pomijała wiele rzeczywistych zakupów. Drzewo decyzyjne lepiej wykrywało zakupy niż regresja logistyczna, ale jego precyzja była niższa. KNN uzyskał najłabszy wynik F1-score dla klasy pozytywnej, co wskazuje na ograniczoną skuteczność tej metody w analizowanym problemie.

Porównanie modeli

Po zbudowaniu i ocenieniu czterech modeli klasyfikacyjnych dokonano ich bezpośredniego porównania. Celem tego etapu było wskazanie modelu, który najlepiej radzi sobie z przewidywaniem, czy dana sesja użytkownika sklepu internetowego zakończy się zakupem. Do porównania wykorzystano podstawowe miary jakości klasyfikacji: accuracy, precision, recall oraz F1-score.

Szczególnie istotną miarą w tym projekcie był F1-score, ponieważ analizowany zbiór danych jest niezbalansowany. Liczba sesji niezakończonych zakupem jest znacznie większa niż liczba sesji zakończonych transakcją. W takiej sytuacji sama dokładność klasyfikacji, czyli accuracy, może być myląca, ponieważ model może osiągać wysoki wynik głównie dzięki poprawnemu rozpoznawaniu klasy większościowej. Z tego powodu większą uwagę zwrócono na miary odnoszące się do klasy pozytywnej, czyli użytkowników, którzy dokonali zakupu.

Miara precision informuje, jaka część obserwacji przewidzianych jako zakup rzeczywiście zakończyła się zakupem. Miara recall pokazuje, jaką część rzeczywistych zakupów model był w stanie wykryć. F1-score łączy obie te miary, dlatego pozwala ocenić kompromis między precyzją a czułością modelu.

Porównanie modeli:					
	Model	Accuracy	Precision	Recall	F1-score
2	Las losowy	0.908234	0.770548	0.589005	0.667656
1	Drzewo decyzyjne	0.859893	0.552083	0.554974	0.553525
0	Regresja logistyczna	0.889390	0.771845	0.416230	0.540816
3	KNN	0.873413	0.668203	0.379581	0.484140

Rysunek 32 Porównanie modeli klasyfikacyjnych według miar accuracy, precision, recall oraz F1-score

Na Rysunku 32 przedstawiono zestawienie wyników czterech modeli klasyfikacyjnych: regresji logistycznej, drzewa decyzyjnego, lasu losowego oraz algorytmu KNN. Modele zostały porównane pod względem czterech miar jakości: accuracy, precision, recall oraz F1-score. Tabela została uporządkowana według wartości F1-score, dzięki czemu na pierwszym miejscu znajduje się model osiągający najlepszy kompromis między precyzją i czułością dla klasy zakupowej.

Najlepszy wynik uzyskał model lasu losowego. Osiągnął on accuracy równą 0,9082, precision równą 0,7705, recall równy 0,5890 oraz F1-score równy 0,6677. Jest to najwyższy wynik F1-score spośród wszystkich analizowanych modeli. Las losowy nie tylko utrzymał wysoką dokładność ogólną, lecz także najlepiej radził sobie z rozpoznawaniem sesji zakończonych zakupem.

Drugie miejsce zajął model drzewa decyzyjnego, który uzyskał F1-score równy 0,5535. Model ten osiągnął niższą dokładność ogólną niż regresja logistyczna i KNN, jednak miał wyższy recall dla klasy pozytywnej. Dzięki temu lepiej wykrywał rzeczywiste zakupy niż modele bardziej zachowawcze, ale kosztem niższej precyzji.

Regresja logistyczna uzyskała accuracy równą 0,8894 oraz wysoką precision równą 0,7718, jednak jej recall wyniósł tylko 0,4162. Model ten był więc dość precyzyjny wtedy, gdy przewidywał zakup, ale wykrywał stosunkowo niewielką część rzeczywistych sesji zakupowych. W efekcie jego F1-score wyniósł 0,5408.

Najniższy wynik F1-score uzyskał model KNN, dla którego wartość tej miary wyniosła 0,4841. Model osiągnął accuracy na poziomie 0,8734, ale miał najniższy recall, równy

0,3796. W praktyce wskazuje to, że KNN miał największy problem z identyfikacją użytkowników, którzy faktycznie dokonali zakupu.

Na podstawie tabeli można stwierdzić, że najlepszym modelem w analizowanym porównaniu był las losowy. Model ten osiągnął najwyższą wartość F1-score, a jednocześnie zachował wysoką dokładność i precyzję. Wynik ten potwierdza, że metoda zespołowa oparta na wielu drzewach decyzyjnych lepiej radziła sobie ze złożonością danych niż pojedyncze drzewo, regresja logistyczna oraz KNN.

Walidacja krzyżowa

W celu sprawdzenia stabilności uzyskanych wyników zastosowano 5-krotną walidację krzyżową. Etap ten był istotny, ponieważ wcześniejsze wyniki modeli zostały obliczone dla jednego konkretnego podziału danych na zbiór treningowy i testowy. Taki pojedynczy podział może częściowo wpływać na ocenę modelu, zwłaszcza wtedy, gdy dane są niezbalansowane, a liczba obserwacji klasy pozytywnej jest znacznie mniejsza niż liczba obserwacji klasy negatywnej.

W projekcie wykorzystano metodę StratifiedKFold, czyli stratyfikowaną walidację krzyżową. Oznacza to, że w każdym z pięciu podziałów zachowano zbliżone proporcje klas zmiennej docelowej Revenue. Jest to szczególnie ważne w analizowanym zbiorze, ponieważ sesje zakończone zakupem stanowią mniejszość wszystkich obserwacji. Bez zastosowania stratyfikacji mogłoby dojść do sytuacji, w której w niektórych podzbiorach walidacyjnych liczba przypadków klasy zakupowej byłaby zbyt mała, co zniekształciłoby ocenę jakości modeli.

Walidacja krzyżowa polegała na pięciokrotnym podziale danych na części treningowe i walidacyjne. W każdej iteracji model był trenowany na czterech częściach danych, a następnie oceniany na pozostałej części. Po zakończeniu wszystkich iteracji obliczono średnie wartości miar jakości. Dzięki temu uzyskano bardziej wiarygodną ocenę skuteczności modeli niż w przypadku pojedynczego podziału trening-test.

W walidacji krzyżowej analizowano te same miary, które wykorzystano wcześniej przy ocenie modeli: accuracy, precision, recall oraz F1-score. Szczególną uwagę ponownie zwrócono na F1-score, ponieważ miara ta dobrze nadaje się do porównywania modeli w przypadku niezbalansowanych danych. Łączy ona informację o precyzji i czułości, dlatego pozwala ocenić, czy model nie tylko poprawnie przewiduje zakupy, ale także wykrywa odpowiednio dużą część rzeczywistych transakcji.

Wyniki walidacji krzyżowej:					
	Model	CV Accuracy	CV Precision	CV Recall	CV F1-score
2	Las losowy	0.902704	0.752959	0.562246	0.643545
1	Drzewo decyzyjne	0.857948	0.545339	0.553732	0.549299
0	Regresja logistyczna	0.882016	0.744800	0.372868	0.496579
3	KNN	0.870545	0.658759	0.356458	0.462208

Rysunek 33 Porównanie modeli klasyfikacyjnych na podstawie średnich wyników 5-krotnej walidacji krzyżowej

Na Rysunku 33 przedstawiono wyniki 5-krotnej walidacji krzyżowej dla czterech analizowanych modeli klasyfikacyjnych: regresji logistycznej, drzewa decyzyjnego, lasu losowego oraz KNN. W tabeli uwzględniono średnie wartości czterech miar jakości: CV Accuracy, CV Precision, CV Recall oraz CV F1-score.

Najlepszy wynik walidacji krzyżowej uzyskał model lasu losowego. Średnia dokładność tego modelu wyniosła 0,9027, natomiast średni CV F1-score osiągnął wartość 0,6435. Model ten uzyskał również najwyższą wartość CV Precision, równą 0,7530 oraz najwyższy wynik spośród modeli pod względem równowagi między precyzją i czułością. Potwierdza to, że las losowy nie tylko dobrze wypadł na pojedynczym zbiorze testowym, lecz także zachował relatywnie stabilną jakość przy różnych podziałach danych.

Drugie miejsce pod względem CV F1-score zajęło drzewo decyzyjne, z wynikiem 0,5493. Model ten osiągnął niższą dokładność niż regresja logistyczna i KNN, ale miał wyższy CV Recall, równy 0,5537. Oznacza to, że drzewo decyzyjne lepiej wykrywało przypadki klasy pozytywnej niż regresja logistyczna i KNN, choć odbywało się to kosztem niższej precyzji.

Regresja logistyczna uzyskała średnią dokładność równą 0,8820 oraz CV Precision na poziomie 0,7448, czyli wynik zbliżony do lasu losowego pod względem precyzji. Jej istotnym ograniczeniem był jednak niski CV Recall, wynoszący 0,3729. Model ten przewidywał zakupy dość ostrożnie; gdy wskazywał klasę pozytywną, często robił to trafnie, ale pomijał dużą część rzeczywistych zakupów. Z tego względu jego CV F1-score wyniósł 0,4966.

Najniższy wynik CV F1-score uzyskał model KNN, dla którego wartość tej miary wyniosła 0,4622. Model osiągnął średnią dokładność równą 0,8705, jednak jego CV Recall był najniższy spośród analizowanych metod i wyniósł 0,3565. Wskazuje to, że KNN miał największe trudności z wykrywaniem sesji zakończonych zakupem.

Wyniki walidacji krzyżowej potwierdzają wcześniejsze wnioski z porównania modeli na zbiorze testowym. Las losowy pozostał najlepszym modelem również przy ocenie krzyżowej, co zwiększa wiarygodność uzyskanego rezultatu. Model ten osiągnął najwyższy CV F1-score, a więc najlepiej równoważył zdolność wykrywania zakupów z ograniczaniem błędnych predykcji. Z tego względu został wybrany jako główny model do dalszej analizy.

Ocena stabilności najlepszego modelu metodą bootstrap

Po przeprowadzeniu walidacji krzyżowej jako najlepszy model wskazano las losowy, ponieważ uzyskał najwyższą średnią wartość miary CV F1-score. W celu dodatkowej oceny stabilności tego modelu zastosowano metodę bootstrap. Metoda ta została wykorzystana do oszacowania przedziału ufności dla średniej wartości dokładności klasyfikacji, czyli accuracy.

Bootstrap jest techniką polegającą na wielokrotnym losowaniu próbek z dostępnych wyników z zastępowaniem. W tym przypadku podstawą były wyniki accuracy uzyskane przez model lasu losowego w kolejnych częściach walidacji krzyżowej. Następnie wielokrotnie losowano z tych wyników próby bootstrapowe i dla każdej z nich obliczano średnią wartość dokładności. Na tej podstawie wyznaczono rozkład średniej accuracy oraz 95% przedział ufności.

Wyniki dokładności dla modelu lasu losowego w kolejnych foldach wyniosły:


0.9037, 0.8991, 0.9022, 0.9037, 0.9047.

Średnia wartość accuracy wyniosła 0,9027, co oznacza, że model poprawnie klasyfikował około 90,27% obserwacji w ramach walidacji krzyżowej. Oszacowany 95% przedział ufności wyniósł [0,9010; 0,9041]. Przedział ten jest wąski, co wskazuje na niewielką zmienność średniej dokładności modelu w analizowanych próbach bootstrapowych.

Uzyskany wynik sugeruje, że model lasu losowego charakteryzuje się stabilną jakością klasyfikacji pod względem miary accuracy. Bootstrap potraktowano jako uzupełnienie wcześniejszej oceny modelu, a nie jako jedyne kryterium wyboru najlepszego algorytmu. Kluczowe znaczenie nadal miała wartość F1-score, ponieważ

lepiej odzwierciedla ona zdolność modelu do rozpoznawania klasy pozytywnej, czyli sesji zakończonych zakupem.

Warto również zaznaczyć, że bootstrap został zastosowany do wyników uzyskanych w walidacji krzyżowej, a nie bezpośrednio do całego zbioru danych. Dlatego otrzymany przedział ufności należy interpretować jako przybliżoną ocenę stabilności średniej dokładności modelu na podstawie dostępnych wyników walidacyjnych.



Rysunek 34 Rozkład średniej accuracy modelu lasu losowego uzyskany metodą bootstrap wraz z 95% przedziałem ufności

Na Rysunku 34 przedstawiono rozkład średniej wartości accuracy uzyskany metodą bootstrap dla najlepszego modelu, czyli lasu losowego. Na osi poziomej zaprezentowano średnią dokładność klasyfikacji, natomiast oś pionowa pokazuje liczbę wystąpień poszczególnych wartości w próbach bootstrapowych.

Histogram przedstawia, jak często w powtórzonych losowaniach pojawiały się określone wartości średniej accuracy. Większość wyników koncentruje się w okolicach wartości 0,902–0,903, co jest zgodne z obliczoną średnią dokładnością równą 0,9027. Taki układ wskazuje, że model uzyskuje zbliżone wartości skuteczności w kolejnych próbach, a jego wynik nie jest silnie rozproszony.

Na wykresie zaznaczono również dwie pionowe linie przerywane, które przedstawiają dolną i górną granicę 95% przedziału ufności. Dolna granica wynosi około 0,9010, natomiast górna około 0,9041. Oznacza to, że na podstawie zastosowanej procedury bootstrapowej można przyjąć, iż średnia dokładność modelu lasu losowego mieści się z dużym prawdopodobieństwem w tym zakresie.

Kształt rozkładu jest stosunkowo skupiony wokół średniej, a szerokość przedziału ufności jest niewielka. Wskazuje to na stabilność modelu pod względem ogólnej dokładności klasyfikacji. Jednocześnie, ze względu na niezbalansowanie klas, wynik ten należy interpretować łącznie z wcześniejszymi miarami, przede wszystkim precision, recall oraz F1-score.

Strojenie hiperparametrów

Po porównaniu modeli klasyfikacyjnych oraz przeprowadzeniu walidacji krzyżowej do dalszej analizy wybrano model Random Forest, czyli las losowy. Model ten uzyskał najlepsze wyniki spośród analizowanych metod, szczególnie pod względem miary F1-score, która była istotna ze względu na niezbalansowany charakter zmiennej docelowej Revenue.

W kolejnym etapie przeprowadzono strojenie hiperparametrów modelu Random Forest za pomocą metody GridSearchCV. Celem tego działania było znalezienie takiej kombinacji parametrów modelu, która pozwala uzyskać możliwie najlepszy wynik predykcyjny. W odróżnieniu od parametrów uczonych automatycznie w trakcie treningu, hiperparametry są ustawieniami modelu określanymi przed procesem uczenia. Ich odpowiedni dobór może wpływać na skuteczność klasyfikacji, stabilność modelu oraz jego podatność na przeuczenie.

Metoda GridSearchCV polega na sprawdzeniu wielu kombinacji zadanych hiperparametrów. Dla każdej kombinacji model jest oceniany za pomocą walidacji krzyżowej, a następnie wybierany jest zestaw parametrów, który osiągnął najlepszy wynik według przyjętej miary jakości. W tym projekcie jako kryterium wyboru wykorzystano F1-score, ponieważ miara ta uwzględnia zarówno precyzję, jak i czułość modelu w rozpoznawaniu klasy pozytywnej, czyli sesji zakończonych zakupem.

W ramach strojenia sprawdzano przede wszystkim następujące hiperparametry:

`n_estimators` - liczba drzew w lesie losowym. Parametr ten określa, ile pojedynczych drzew decyzyjnych zostanie zbudowanych w ramach modelu zespołowego. Większa

liczba drzew zwykle zwiększa stabilność modelu i może poprawić jakość predykcji, ale jednocześnie wydłuża czas obliczeń.

max_depth - maksymalna głębokość pojedynczego drzewa. Parametr ten kontroluje, jak złożone mogą być drzewa decyzyjne. Zbyt duża głębokość może prowadzić do przeuczenia modelu, ponieważ drzewo może zbyt dokładnie dopasować się do danych treningowych. Zbyt mała głębokość może natomiast spowodować niedouczenie modelu i zbyt uproszczone odwzorowanie zależności.

min_samples_split - minimalna liczba obserwacji wymagana do podziału węzła. Parametr ten określa, ile próbek musi znajdować się w danym węźle, aby model mógł dokonać dalszego podziału. Większa wartość tego parametru ogranicza złożoność drzewa i może zmniejszać ryzyko przeuczenia.

min_samples_leaf - minimalna liczba obserwacji w liściu drzewa. Liść to końcowy węzeł drzewa, w którym podejmowana jest decyzja klasyfikacyjna. Zwiększenie tego parametru powoduje, że model tworzy bardziej ogólne reguły, ponieważ nie pozwala na tworzenie bardzo małych grup obserwacji. Może to poprawić zdolność generalizacji modelu.

Tabela 3. Hiperparametry modelu Random Forest sprawdzane w procedurze GridSearchCV

Hiperparametr	Sprawdzone wartości	Najlepsza wartość	Znaczenie parametru	Interpretacja uzyskanego wyniku
n_estimators	100, 200	200	Określa liczbę drzew decyzyjnych budowanych w ramach lasu losowego.	Najlepszy wynik uzyskano dla 200 drzew. Większa liczba drzew poprawiła stabilność modelu i jakość klasyfikacji.
max_depth	None, 5, 10	None	Określa maksymalną głębokość pojedynczego drzewa decyzyjnego.	Brak ograniczenia głębokości pozwolił modelowi lepiej odwzorować zależności występujące w danych. Należy jednak kontrolować ryzyko przeuczenia.
min_samples_split	2, 5	5	Określa minimalną liczbę obserwacji wymaganą do dalszego podziału węzła.	Wartość 5 ograniczyła tworzenie zbyt szczegółowych podziałów, co mogło poprawić zdolność modelu do generalizacji.
min_samples_leaf	1, 2	1	Określa minimalną liczbę obserwacji, które muszą znaleźć się w końcowym liściu drzewa.	Wartość 1 pozwoliła modelowi tworzyć bardziej szczegółowe reguły decyzyjne, co w analizowanym przypadku dało najlepszy wynik F1-score.

Wyniki dostrojonego Random Forest na zbiorze testowym:				
	precision	recall	f1-score	support
0	0.93	0.96	0.94	2059
1	0.74	0.58	0.65	382
accuracy			0.90	2441
macro avg	0.83	0.77	0.80	2441
weighted avg	0.90	0.90	0.90	2441

Rysunek 35 Wyniki dostrojonego modelu Random Forest na zbiorze testowym po zastosowaniu GridSearchCV

Na Rysunku 35 przedstawiono wyniki dostrojonego modelu Random Forest na zbiorze testowym. Raport klasyfikacji obejmuje wartości precision, recall, f1-score oraz support dla obu klas zmiennej docelowej. Klasa 0 oznacza sesje niezakończone zakupem, natomiast klasa 1 oznacza sesje zakończone zakupem.

Dla klasy 0 model uzyskał bardzo dobre wyniki: precision wyniosło 0,93, recall 0,96, a f1-score 0,94. Pokazuje to, że dostrojony Random Forest bardzo dobrze rozpoznawał sesje, które nie zakończyły się zakupem. Jest to jednak klasa większościowa, dlatego wysokie wyniki dla tej klasy były częściowo spodziewane.


W przypadku klasy 1, czyli sesji zakończonych zakupem, model uzyskał precision równą 0,74, recall równy 0,58 oraz f1-score równy 0,65. Wyniki te są niższe niż dla klasy 0, co wynika z niezbalansowanego charakteru zbioru danych. Mimo to model zachował relatywnie dobrą skuteczność w rozpoznawaniu klasy zakupowej w porównaniu z pozostałymi analizowanymi algorytmami.

Ogólna dokładność modelu na zbiorze testowym wyniosła 0,90. Oznacza to, że około 90% obserwacji zostało poprawnie sklasyfikowanych. Warto jednak podkreślić, że w tym projekcie sama accuracy nie jest wystarczającą miarą jakości modelu. Ze względu na przewagę klasy 0, najważniejsza była skuteczność rozpoznawania klasy 1, oceniana za pomocą precision, recall oraz F1-score.

Wartość macro avg dla F1-score wyniosła 0,80, natomiast weighted avg dla F1-score wyniosła 0,90. Różnica między tymi wartościami wynika z nierównych liczebności klas.

Średnia ważona jest silniej zależna od klasy większościowej, dlatego daje bardziej optymistyczny obraz jakości modelu. Średnia makro traktuje obie klasy jednakowo, dlatego lepiej pokazuje, że model wyraźnie lepiej radzi sobie z klasą 0 niż z klasą 1.

Podsumowując, strojenie hiperparametrów pozwoliło uzyskać dobrze dopasowany model Random Forest o wysokiej ogólnej skuteczności i relatywnie dobrej zdolności identyfikowania sesji zakupowych. Wyniki potwierdzają, że las losowy pozostaje najlepszym modelem spośród analizowanych metod.



Rysunek 36 Macierz pomyłek dla dostrojonego modelu Random Forest na zbiorze testowym

Na Rysunku 36 przedstawiono macierz pomyłek dla dostrojonego modelu Random Forest po zastosowaniu procedury doboru hiperparametrów. Macierz pomyłek pokazuje, w jaki sposób model klasyfikował obserwacje ze zbioru testowego, porównując wartości rzeczywiste ze wskazaniem modelu. Na osi pionowej znajdują się wartości rzeczywiste, natomiast na osi poziomej predykcje modelu.

Klasa 0 oznacza sesje niezakończone zakupem, natomiast klasa 1 oznacza sesje zakończone zakupem. Model poprawnie zaklasyfikował 1980 sesji jako brak zakupu. Są to przypadki, w których rzeczywista wartość wynosiła 0 i model również przewidział

0. Jest to największa grupa w macierzy, co wynika z niezbalansowanego charakteru danych - w zbiorze testowym dominują sesje niezakończone zakupem.

Model poprawnie rozpoznał również 222 sesje zakończone zakupem. Są to przypadki, w których rzeczywista wartość wynosiła 1 i model przewidywał 1. Ta wartość jest szczególnie istotna z perspektywy biznesowej, ponieważ pokazuje, ilu użytkowników faktycznie dokonujących zakupu zostało poprawnie zidentyfikowanych przez model.

W macierzy widoczne są także błędne klasyfikacje. Model błędnie oznaczył 79 sesji niezakończonych zakupem jako sesje zakupowe. Są to przypadki fałszywie pozytywne. W praktyce mogłyby one oznaczać użytkowników, którym system przypisał wysokie prawdopodobieństwo zakupu, mimo że finalnie nie dokonali transakcji.

Drugim rodzajem błędu są przypadki fałszywie negatywne. Model zaklasyfikował 160 rzeczywistych zakupów jako brak zakupu. Jest to ważne ograniczenie modelu, ponieważ oznacza, że część użytkowników, którzy faktycznie dokonali zakupu, nie została przez model rozpoznana jako potencjalni klienci zakupowi.

Wyniki macierzy pomyłek wskazują, że dostrojony Random Forest bardzo dobrze rozpoznaje klasę większościową, czyli sesje bez zakupu. Jednocześnie model wykrywa znaczną część sesji zakończonych zakupem, choć nadal popełnia błędy polegające na pomijaniu części rzeczywistych transakcji.


Z perspektywy oceny modelu szczególnie ważne jest, że liczba poprawnie wykrytych zakupów jest większa niż liczba zakupów pominiętych tylko częściowo, ale model nadal nie identyfikuje wszystkich przypadków klasy 1. Dlatego jego jakość należy oceniać nie tylko przez ogólną dokładność, lecz także przez precision, recall oraz F1-score dla klasy pozytywnej.

Krzywa ROC i AUC

W kolejnym etapie oceny najlepszego modelu wykorzystano krzywą ROC oraz miarę AUC. Analiza ta została przeprowadzona dla modelu Random Forest, który wcześniej uzyskał najlepsze wyniki spośród porównywanych modeli klasyfikacyjnych.

Krzywa ROC pozwala ocenić zdolność modelu do rozróżniania dwóch klas: sesji zakończonych zakupem oraz sesji niezakończonych zakupem. Na osi poziomej znajduje się wskaźnik fałszywie pozytywnych klasyfikacji, czyli False Positive Rate, natomiast na osi pionowej wskaźnik prawdziwie pozytywnych klasyfikacji, czyli True

Positive Rate. Im bardziej krzywa znajduje się w lewym górnym rogu wykresu, tym lepsza jest zdolność modelu do odróżniania klasy pozytywnej od negatywnej.



Rysunek 37 Krzywa ROC oraz wartość AUC dla modelu Random Forest

Na Rysunku 37 przedstawiono krzywą ROC dla modelu Random Forest. Niebieska linia pokazuje skuteczność modelu przy różnych progach klasyfikacji, natomiast pomarańczowa linia przerywana oznacza model losowy, czyli punkt odniesienia dla oceny jakości klasyfikatora. Model losowy nie rozróżnia klas w sposób użyteczny, dlatego jego krzywa przebiega po przekątnej wykresu.

Krzywa ROC modelu Random Forest przebiega zdecydowanie powyżej linii modelu losowego i szybko zbliża się do lewego górnego obszaru wykresu. Świadczy to o tym, że model dobrze odróżnia sesje zakończone zakupem od sesji bez zakupu. Przy relatywnie niskim poziomie fałszywie pozytywnych wskazań model osiąga wysoką wartość wskaźnika prawdziwie pozytywnych klasyfikacji. Jest to korzystne, ponieważ oznacza, że model potrafi wykrywać znaczną część użytkowników dokonujących zakupu bez nadmiernego zwiększania liczby błędnych wskazań.

Wartość AUC wyniosła 0,9283, co wskazuje na wysoką zdolność modelu do rozróżniania klas. Wynik ten można interpretować jako bardzo dobry. Model Random Forest posiada więc silną zdolność rankingową - użytkownicy, którzy faktycznie dokonali zakupu, otrzymują zwykle wyższe prawdopodobieństwo klasy pozytywnej niż użytkownicy, którzy zakupu nie dokonali.

Analiza ważności cech

Po wybraniu najlepszego modelu klasyfikacyjnego przeprowadzono analizę ważności cech. Celem tego etapu było sprawdzenie, które zmienne miały największy wpływ na predykcje wykonywane przez model Random Forest. Analiza ważności cech pozwala lepiej zrozumieć działanie modelu i wskazać, które informacje o sesji użytkownika były najczęściej wykorzystywane przy klasyfikowaniu, czy dana sesja zakończy się zakupem.

W przypadku modelu Random Forest ważność cech obliczana jest na podstawie tego, jak bardzo dana zmienna przyczynia się do poprawy jakości podziałów w drzewach decyzyjnych tworzących las losowy. Im wyższa wartość ważności cechy, tym większe znaczenie miała ona w procesie podejmowania decyzji przez model.

PageValues	0.402388
ProductRelated_Duration	0.086884
ExitRates	0.084879
ProductRelated	0.068550
Administrative_Duration	0.054967
BounceRates	0.054827
Administrative	0.040561
TrafficType	0.027381
Region	0.025471
Informational_Duration	0.025259
Month_Nov	0.024422
Browser	0.016902
Informational	0.016231
OperatingSystems	0.015105
VisitorType_Returning_Visitor	0.011131

Rysunek 38 Tabełaryczne zestawienie piętnastu najważniejszych cech według modelu Random Forest

Na Rysunku 38 przedstawiono tabelaryczne zestawienie piętnastu najważniejszych cech według modelu Random Forest. W tabeli widoczne są nazwy zmiennych oraz odpowiadające im wartości ważności. Im wyższa wartość, tym większy udział danej zmiennej w procesie klasyfikacji sesji użytkowników.


Najważniejszą cechą okazała się zmienna PageValues, której ważność wyniosła około 0,4024. Jest to wynik zdecydowanie wyższy niż w przypadku pozostałych zmiennych. Oznacza to, że model Random Forest w największym stopniu wykorzystywał informację o wartości odwiedzanych stron przy przewidywaniu, czy użytkownik dokona zakupu. Wynik ten jest zgodny z wcześniejszą analizą korelacji, w której PageValues również wykazywała najsilniejszy dodatni związek ze zmienną docelową Revenue.

Drugą najważniejszą cechą była ProductRelated_Duration, z ważnością około 0,0869. Zmienna ta opisuje czas spędzony przez użytkownika na stronach produktowych. Jej wysoka pozycja w rankingu sugeruje, że czas poświęcony na przeglądanie produktów był istotnym sygnałem dla modelu. Użytkownicy, którzy dłużej analizują strony produktowe, mogą być bardziej zaangażowani w proces zakupowy.

Kolejną istotną zmienną była ExitRates, której ważność wyniosła około 0,0849. Zmienna ta informuje o częstotliwości opuszczania strony przez użytkowników. Jej wysoka pozycja wskazuje, że zachowania związane z kończeniem sesji były ważne dla klasyfikacji. Wysokie wartości ExitRates mogą być powiązane z mniejszym prawdopodobieństwem zakupu, co było widoczne również w analizie korelacji.

Wysoką ważność uzyskały także zmienne ProductRelated, Administrative_Duration, BounceRates oraz Administrative. Zmienne te opisują aktywność użytkownika w sklepie internetowym, liczbę odwiedzonych stron, czas spędzony w określonych częściach serwisu oraz poziom zaangażowania. Ich obecność wśród najważniejszych cech potwierdza, że model opierał swoje predykcje przede wszystkim na informacjach behawioralnych, czyli związanych z faktycznym zachowaniem użytkownika podczas sesji.

Niżej w rankingu znalazły się zmienne techniczne i kontekstowe, takie jak TrafficType, Region, Month_Nov, Browser, OperatingSystems oraz VisitorType_Returning_Visitor. Ich wpływ na decyzje modelu był mniejszy niż wpływ zmiennych bezpośrednio opisujących aktywność użytkownika na stronie. Nie oznacza to jednak, że były całkowicie nieistotne. Mogły one uzupełniać model o informacje dotyczące źródła ruchu, sezonowości, typu użytkownika lub środowiska technicznego.



Rysunek 39 Wykres ważności piętnastu najważniejszych cech w modelu Random Forest

Na Rysunku 39 przedstawiono wykres słupkowy pokazujący piętnaście najważniejszych cech w modelu Random Forest. Na osi pionowej znajdują się nazwy zmiennych, natomiast oś pozioma przedstawia wartość ważności cechy. Dłuższy słupek oznacza większe znaczenie danej zmiennej w procesie klasyfikacji.

Wykres bardzo wyraźnie pokazuje dominującą rolę zmiennej PageValues. Jej słupek jest kilkakrotnie dłuższy niż słupki pozostałych zmiennych, co wskazuje, że była ona najważniejszym predyktorem w modelu. Tak silna przewaga jednej cechy sugeruje, że informacja o wartości odwiedzanych stron była kluczowa dla rozpoznawania sesji zakończonych zakupem.

Wnioski końcowe

Celem projektu było zbudowanie i porównanie modeli uczenia maszynowego służących do przewidywania intencji zakupowej użytkownika sklepu internetowego. Problem został sformułowany jako zadanie klasyfikacji binarnej, w którym zmienna docelowa Revenue określała, czy dana sesja zakończyła się zakupem. Na podstawie przeprowadzonej analizy można stwierdzić, że dane opisujące zachowanie użytkowników w sklepie internetowym pozwalają przewidywać prawdopodobieństwo dokonania zakupu, jednak skuteczność predykcji zależy od wyboru modelu, zastosowanych miar oceny oraz sposobu interpretacji wyników.

Analizowany zbiór danych obejmował początkowo 12 330 obserwacji oraz 18 kolumn. Po kontroli jakości danych usunięto 125 duplikatów, dlatego do dalszych etapów wykorzystano 12 205 obserwacji. W danych nie stwierdzono braków wartości, co uprościło proces przygotowania danych i pozwoliło uniknąć imputacji. Po zakodowaniu zmiennych kategoriycznych i oddzieleniu zmiennej docelowej macierz cech obejmowała 12 205 obserwacji i 26 zmiennych wejściowych. Dane zostały następnie podzielone na zbiór treningowy i testowy z zachowaniem proporcji klas, co było istotne ze względu na niezbalansowany charakter zmiennej docelowej.

Pierwszym istotnym wnioskiem z eksploracyjnej analizy danych jest wyraźna nierównowaga klas. Spośród 12 205 obserwacji 10 297 sesji, czyli około 84,37%, nie zakończyło się zakupem, natomiast 1908 sesji, czyli około 15,63%, zakończyło się dokonaniem zakupu. Jednocześnie niezbalansowanie klas wpływa na sposób oceny modeli. Sama dokładność klasyfikacji nie jest wystarczająca, ponieważ model może osiągać wysoki wynik accuracy, przewidując przede wszystkim klasę większościową. Z tego powodu w projekcie szczególną uwagę poświęcono miarom precision, recall oraz F1-score, zwłaszcza dla klasy pozytywnej, czyli sesji zakończonych zakupem.

Analiza korelacji wykazała, że najsilniejszy dodatni związek ze zmienną docelową Revenue miała zmienna PageValues, dla której współczynnik korelacji wyniósł około 0,492. Oznacza to, że wyższa wartość odwiedzanych stron była wyraźnie powiązana z większym prawdopodobieństwem dokonania zakupu. Dodatkowo, choć słabsze, korelacje uzyskały również zmienne ProductRelated oraz ProductRelated_Duration, co wskazuje, że liczba odwiedzonych stron produktowych oraz czas spędzony przy produktach mogą mieć znaczenie dla decyzji zakupowej. Z kolei zmienne ExitRates i BounceRates były ujemnie skorelowane ze zmienną Revenue, odpowiednio na poziomie około -0,204 oraz -0,145. Wysokie wartości tych wskaźników wiążą się z częstszym opuszczaniem strony i niższym prawdopodobieństwem finalizacji transakcji.

Wizualizacje zmiennych potwierdziły wnioski wynikające z analizy korelacji. Rozkłady zmiennych takich jak PageValues, ProductRelated_Duration, BounceRates i ExitRates były silnie asymetryczne i zawierały obserwacje odstające. Wykresy pudełkowe pokazały, że sesje zakończone zakupem charakteryzowały się wyższymi wartościami PageValues, niższymi wartościami BounceRates i ExitRates oraz nieco większym czasem spędzonym na stronach produktowych. Analiza zmiennych kategoriycznych wskazała dodatkowo, że liczba sesji i zakupów różniła się w

zależności od miesiąca, typu użytkownika oraz tego, czy sesja odbywała się w weekend. Szczególnie widoczna była większa aktywność w maju i listopadzie oraz dominacja użytkowników powracających.

W projekcie zbudowano i porównano cztery modele klasyfikacyjne: regresję logistyczną, drzewo decyzyjne, las losowy oraz metodę k najbliższych sąsiadów. Porównanie wyników na zbiorze testowym wykazało, że najlepszym modelem był las losowy. Uzyskał on accuracy równą 0,9082, precision równą 0,7705, recall równy 0,5890 oraz F1-score równy 0,6677. Był to najwyższy wynik F1-score spośród wszystkich analizowanych modeli, co oznacza najlepszy kompromis między precyzją a czułością dla klasy zakupowej.

Pozostałe modele osiągnęły słabsze wyniki dla klasy pozytywnej. Drzewo decyzyjne uzyskało F1-score równy 0,5535, regresja logistyczna 0,5408, a KNN 0,4841. Regresja logistyczna była stosunkowo precyzyjna wtedy, gdy przewidywała zakup, ale miała niski recall , co oznacza, że pomijała znaczną część rzeczywistych sesji zakończonych zakupem. Drzewo decyzyjne wykrywało więcej zakupów niż regresja logistyczna, ale kosztem większej liczby błędnych wskazań. KNN okazał się najmniej skuteczny w rozpoznawaniu klasy pozytywnej. Wyniki te wskazują, że metoda zespołowa oparta na wielu drzewach decyzyjnych najlepiej poradziła sobie ze złożonością analizowanych danych.

Wyniki 5-krotnej walidacji krzyżowej potwierdziły przewagę modelu lasu losowego. Średnia dokładność tego modelu wyniosła 0,9027, a średni CV F1-score osiągnął wartość 0,6435. Model ten uzyskał najwyższy wynik CV F1-score spośród wszystkich porównanych metod, co wskazuje, że jego przewaga nie była przypadkowym efektem jednego podziału danych na zbiór treningowy i testowy. Zastosowanie stratyfikowanej walidacji krzyżowej było szczególnie ważne, ponieważ pozwoliło zachować proporcje klas w kolejnych podziałach danych.

Dodatkowa ocena stabilności modelu za pomocą metody bootstrap wykazała, że średnia wartość accuracy dla lasu losowego wyniosła 0,9027, a 95% przedział ufności mieścił się w zakresie od 0,9010 do 0,9041. Wąski przedział ufności wskazuje na niewielką zmienność średniej dokładności modelu. Wynik ten potwierdza stabilność modelu pod względem ogólnej skuteczności klasyfikacji. Należy jednak podkreślić, że ze względu na niezbalansowanie klas accuracy nie powinna być traktowana jako jedyna miara jakości. Wyniki bootstrapu należy więc interpretować jako uzupełnienie oceny opartej na F1-score , precision i recall .

W kolejnym etapie przeprowadzono strojenie hiperparametrów modelu Random Forest za pomocą procedury GridSearchCV. Najlepszy zestaw parametrów obejmował 200 drzew, brak ograniczenia maksymalnej głębokości, minimalną liczbę 5 obserwacji wymaganą do podziału węzła oraz minimalną liczbę 1 obserwacji w liściu. Najlepszy wynik F1-score uzyskany w procedurze GridSearchCV wyniósł 0,6513. Wyniki dostrojonego modelu na zbiorze testowym były zbliżone do wyników modelu bazowego. Oznacza to, że strojenie hiperparametrów nie doprowadziło do radykalnej poprawy jakości, ale potwierdziło, że las losowy był właściwym i stabilnym wyborem dla analizowanego problemu.

Ocena modelu za pomocą krzywej ROC i miary AUC również potwierdziła dobrą jakość klasyfikatora. Wartość AUC wyniosła 0,9283, co wskazuje na wysoką zdolność modelu do rozróżniania sesji zakończonych zakupem od sesji bez zakupu. Krzywa ROC przebiegała zdecydowanie powyżej linii modelu losowego, co oznacza, że Random Forest skutecznie porządkował obserwacje według prawdopodobieństwa przynależności do klasy pozytywnej.

Analiza ważności cech wykazała, że najważniejszą zmienną w modelu Random Forest była PageValues, której ważność wyniosła około 0,4024. Była to wartość wyraźnie wyższa niż dla pozostałych cech, co potwierdza kluczowe znaczenie wartości odwiedzanych stron dla przewidywania zakupu. Kolejne istotne zmienne to ProductRelated_Duration, ExitRates, ProductRelated, Administrative_Duration oraz BounceRates. Wyniki te pokazują, że największe znaczenie predykcyjne miały cechy behawioralne, czyli opisujące rzeczywiste zachowanie użytkownika w trakcie sesji. Zmienne techniczne i kontekstowe, takie jak TrafficType, Region, Browser, OperatingSystems, Month_Nov czy VisitorType_Returning_Visitor, miały mniejsze znaczenie, ale mogły uzupełniać model o dodatkowe informacje.

Na podstawie przeprowadzonych analiz można odpowiedzieć na postawione pytania badawcze. Po pierwsze, dane opisujące zachowanie użytkownika na stronie internetowej pozwalają przewidywać dokonanie zakupu, choć problem jest trudniejszy ze względu na niezbalansowany rozkład klas. Po drugie, spośród porównanych modeli najlepszy okazał się las losowy, ponieważ uzyskał najwyższy F1-score zarówno na zbiorze testowym, jak i w walidacji krzyżowej. Po trzecie, największe znaczenie dla predykcji miały zmienne związane z wartością odwiedzanych stron, czasem spędzonym na stronach produktowych, liczbą stron produktowych oraz wskaźnikami

opuszczania strony. Po czwarte, wyniki najlepszego modelu można uznać za stabilne, ponieważ zostały potwierdzone przez walidację krzyżową oraz analizę bootstrap.

Z praktycznego punktu widzenia model tego typu może być wykorzystany w sklepie internetowym do identyfikacji użytkowników o podwyższonym prawdopodobieństwie dokonania zakupu. Wyniki modelu mogłyby wspierać działania marketingowe, personalizację oferty, rekomendacje produktów, kierowanie komunikatów promocyjnych lub uruchamianie dodatkowego wsparcia dla użytkowników znajdujących się blisko decyzji zakupowej. Szczególnie istotne są informacje o wartości odwiedzanych stron oraz aktywności na stronach produktowych, ponieważ to one najlepiej odzwierciedlają realne zaangażowanie użytkownika.

Należy jednak wskazać również ograniczenia projektu. Po pierwsze, dane są niezbalansowane, co utrudnia rozpoznawanie klasy zakupowej i wymaga stosowania odpowiednich miar oceny. Po drugie, część zmiennych technicznych, takich jak OperatingSystems, Browser, Region i TrafficType, została zapisana liczbowo, choć w sensie analitycznym ma charakter kategoriowy. W przyszłych analizach warto rozważyć ich pełne zakodowanie jako zmiennych jakościowych. Po trzecie, niektóre zmienne, zwłaszcza PageValues, mogą być silnie związane z informacją o konwersji, dlatego przy wdrożeniu produkcyjnym należałoby sprawdzić, czy są dostępne w momencie rzeczywistej predykcji, a nie dopiero po zakończeniu sesji. Po czwarte, model został oceniony na jednym zbiorze danych, dlatego przed wdrożeniem w konkretnym sklepie internetowym wymagałby ponownej walidacji na aktualnych danych biznesowych.

Podsumowując, projekt zrealizował pełny proces analityczny z zakresu uczenia maszynowego: od określenia problemu badawczego, przez eksplorację i przygotowanie danych, po budowę, ocenę i interpretację modeli klasyfikacyjnych. Najlepszym modelem okazał się Random Forest, który osiągnął najwyższą jakość klasyfikacji i dobrą stabilność wyników. Najważniejsze dla predykcji zakupu były zmienne behawioralne, przede wszystkim PageValues, ProductRelated_Duration, ExitRates, ProductRelated i BounceRates. Wyniki projektu potwierdzają, że dane o zachowaniu użytkowników sklepu internetowego mogą być użytecznym źródłem informacji w predykcji intencji zakupowej oraz mogą wspierać podejmowanie decyzji biznesowych w obszarze e-commerce.

Spis rysunków

Rysunek 1 Pierwsze pięć wierszy zbioru danych	7
Rysunek 2 Pierwsze pięć wierszy zbioru danych cd.	7
Rysunek 3 Rozmiar zbioru danych	8
Rysunek 4 Informacje o typach danych	9
Rysunek 5 Informacje o typach danych	12
Rysunek 6 Podstawowe statystyki opisowe	13
Rysunek 7 Podstawowe statystyki opisowe cd.	14
Rysunek 8 Analiza braków danych	15
Rysunek 9 Liczba duplikatów w zbiorze danych\.....	16
Rysunek 10 Rozkład zmiennej docelowej Revenue	17
Rysunek 11 Wizualizacja rozkładu zmiennej docelowej Revenue	19
Rysunek 12 Macierz korelacji zmiennych numerycznych z uwzględnieniem zmiennej docelowej Revenue	20
Rysunek 13 Korelacja zmiennych numerycznych ze zmienną docelową Revenue .	22
Rysunek 14 Zmienne wybrane do dokładniejszej analizy na podstawie korelacji i interpretacji biznesowej	23
Rysunek 15 Rozkład zmiennej PageValues opisującej wartość odwiedzanych stron z punktu widzenia konwersji	24
Rysunek 16 Rozkład zmiennej BounceRates opisującej współczynnik odrzuceń użytkowników sklepu internetowego	26
Rysunek 17 Rozkład zmiennej ExitRates opisującej współczynnik wyjść ze strony internetowej	27
Rysunek 18 Rozkład zmiennej ProductRelated_Duration przedstawiającej czas spędzony na stronach produktowych	28
Rysunek 19 Rozkład zmiennej PageValues względem zmiennej docelowej Revenue	29
Rysunek 20 Rozkład zmiennej BounceRates względem zmiennej docelowej Revenue	31
Rysunek 21 Rozkład zmiennej ExitRates względem zmiennej docelowej Revenue	32
Rysunek 22 Rozkład zmiennej ProductRelated_Duration względem zmiennej docelowej Revenue	33
Rysunek 23 Liczba sesji w poszczególnych miesiącach z podziałem na zmienną docelową Revenue	35
Rysunek 24 Liczba sesji według typu użytkownika z podziałem na zmienną docelową Revenue	36
Rysunek 25 Liczba sesji w dni robocze i weekendy z podziałem na zmienną docelową Revenue	37
Rysunek 26 Przygotowanie danych do modelowania: kodowanie zmiennych, podział na zbiór treningowy i testowy oraz standaryzacja cech	39
Rysunek 27 Rozmiar macierzy cech X oraz wektora zmiennej docelowej y po kodowaniu zmiennych kategoriowych	40
Rysunek 28 Raport klasyfikacji i macierz pomyłek dla modelu regresji logistycznej	42

Rysunek 29 Raport klasyfikacji i macierz pomyłek dla modelu drzewa decyzyjnego	43
Rysunek 30 Raport klasyfikacji i macierz pomyłek dla modelu lasu losowego	44
Rysunek 31 Raport klasyfikacji i macierz pomyłek dla modelu KNN	46
Rysunek 32 Porównanie modeli klasyfikacyjnych według miar accuracy, precision, recall oraz F1-score	48
Rysunek 33 Porównanie modeli klasyfikacyjnych na podstawie średnich wyników 5-krotnej walidacji krzyżowej	50
Rysunek 34 Rozkład średniej accuracy modelu lasu losowego uzyskany metodą bootstrap wraz z 95% przedziałem ufności	52
Rysunek 35 Wyniki dostrojonego modelu Random Forest na zbiorze testowym po zastosowaniu GridSearchCV	55
Rysunek 36 Macierz pomyłek dla dostrojonego modelu Random Forest na zbiorze testowym	56
Rysunek 37 Krzywa ROC oraz wartość AUC dla modelu Random Forest	58
Rysunek 38 Tabelaryczne zestawienie piętnastu najważniejszych cech według modelu Random Forest	59
Rysunek 39 Wykres ważności piętnastu najważniejszych cech w modelu Random Forest	61

Spis tabel

Tabela 1. Podstawowa charakterystyka zbioru danych.

Tabela 2. Grupy zmiennych wykorzystanych w projekcie.

Tabela 3. Hiperparametry modelu Random Forest sprawdzane w procedurze GridSearchCV.

Źródło danych

<https://archive.ics.uci.edu/dataset/468/online+shoppers+purchasing+intention+dataset>